

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«УФИМСКИЙ УНИВЕРСИТЕТ НАУКИ И ТЕХНОЛОГИЙ»

ИНСТИТУТ ИНФОРМАТИКИ, МАТЕМАТИКИ И РОБОТОТЕХНИКИ
КАФЕДРА ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ И КИБЕРНЕТИКИ

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
ПО ПРОГРАММЕ МАГИСТРАТУРЫ
(ПРОЕКТНАЯ)

СЕМЕНОВ КИРИЛЛ СТАНИСЛАВОВИЧ

РАЗРАБОТКА ПРОГРАММНОГО ОБЕСПЕЧЕНИЯ ЗАДАЧИ
АНАЛИЗА ВЛИЯНИЯ ИНФОРМАЦИИ В СМИ НА КУРСЫ АКЦИЙ.

Заведующий кафедрой ВМиК
д.т.н., проф.  Г.Р. Шахматова

Выполнил:
Студент 2 курса очной формы обучения
Направление подготовки
09.04.01 «Информатика и
вычислительная техника»
Профиль: «Компьютерный анализ и
интерпретация данных»

Руководитель: 
к.ф.-м.н., доцент Е.И. Прокудина

Консультант: 
к.ф.-м.н., доцент Е.И. Прокудина

Нормоконтролер: 
д.т.н., профессор Г.Р. Воробьева

ФГБОУ ВО «Уфимский университет науки и технологий»

Институт информатики, математики и робототехники
Кафедра Вычислительной математики и кибернетики

Зав. кафедрой Г.Р. Шахмаметова «УТВЕРЖДАЮ»

« 5 » февраля 2024 г.

ЗАДАНИЕ

по подготовке выпускной квалификационной работы

обучающемуся Семенову Кириллу Станиславовичу группы КАИД-212М
(фамилия, имя, отчество)

1. Тема выпускной квалификационной работы: Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций. (утверждена распоряжением по Университету от 16.02.2024 г. № 0505)

Тема спецчасти выпускной квалификационной работы не предусмотрена.

2. Срок сдачи обучающимся законченной выпускной квалификационной работы: 19.06.2024

3. Исходные данные к выпускной квалификационной работе: информационные интернет-ресурсы, множество компаний

4. Перечень вопросов, подлежащих разработке в выпускной квалификационной работе (краткое содержание, при необходимости с указанием разделов):

Провести аналитический обзор предметной области; Составить общую методику работы создаваемой системы прогнозирования; Провести сбор данных, получить новостные данные, а также котировки; Провести предобработку текстовых данных новостей, привести в вид, понятный для модели нейронной сети; Создать и обучить модели нейронных сетей, способных предсказывать будущую цену акции, на основе прошлых данных котировок и новостного потока; Провести вычислительный эксперимент на основе полученных моделей нейросетей. Реализовать программное обеспечение для выдачи прогноза, основанное на полученных моделях нейронных сетей.

5. Цель и объем патентных исследований работы: не предусмотрены

6. Объем и степень использования программного обеспечения : программное обеспечение разработано в среде Pycharm 2024 на языке Python версии 3.11.3, с базой данных PostgreSQL 16, с использованием библиотек Pandas, Numpy, Keras, Selenium, Apache Airflow и др.

8. Перечень графического материала (с указанием вида обязательных чертежей):

Всего не менее _____ листов.


Консультанты выпускной квалификационной работы _____ (Е.И. Прокудин)
подпись фамилия, инициалы

Руководитель И. В. Прокудина

« 5 » февраля 2024 г.

ФГБОУ ВО «Уфимский университет науки и технологий»

Институт информатики, математики и робототехники
Кафедра Вычислительной математики и кибернетики

Зав. кафедрой  «УТВЕРЖДАЮ»
Г.Р. Шахматова

« 5 » февраля 2024 г.


КАЛЕНДАРНЫЙ ПЛАН работы над выпускной квалификационной работой

обучающегося: Семенова Кирилла Станиславовича группы КАИД-212М
(фамилия, имя, отчество)

Тема выпускной квалификационной работы Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций.

Тема спецчасти: не предусмотрена.

№ п/п	Наименование разделов выпускной квалификационной работы	Срок	Объем (в % от всей выпускной квалификационной работы)	Фактическое (объем работы в %)
Расчет и описание				
1	Введение, теоретическо-аналитическая часть	13.05.2024	50	60
2	Проектная часть, Заключение, Приложения	11.06.2024	90	95
Графические документы			Объем в листах	
3	Не предусмотрены	-	-	-

Обучающийся:  « 5 » февраля 2024 г.
(подпись)

Руководитель выпускной квалификационной работы:  « 5 » февраля 2024 г.
(подпись)

Примечание: Календарный план работы над выпускной квалификационной работой должен быть разработан обучающимся до начала написания выпускной квалификационной работы.

Ход выполнения выпускной квалификационной работы:

Дата просмотра выпускной квалификационной работы на кафедре	13.05.2024	11.06.2024	19.06.2024
Объем выполнения выпускной квалификационной работы в %	55	95	100

Дата защиты выпускной квалификационной работы на заседании ГЭК « 24 » июня 2024 г.

ПАМЯТКА ДИПЛОМНИКУ

Дипломник должен:

1. Придерживаться следующей рекомендуемой последовательности подшивки документов:
 - титульный лист;
 - задание по подготовке выпускной квалификационной работы;
 - календарный план;
 - аннотация;
 - содержание;
 - введение;
 - разделы ВКР (в соответствии с требованиями к написанию выпускной квалификационной работы по направлению (специальности))
 - заключение;
 - список литературы;
 - приложения;
 - отзыв руководителя;
 - справка о результатах проверки ВКР на плагиат

Первым листом пояснительной записки считается титульный лист. Нумерацию листов выпускной квалификационной работы начинать с листа, на котором располагается основная надпись.

Для защиты выпускной квалификационной работы в установленный срок, обучающийся должен:

2. Представить выпускную квалификационную работу в срок не позднее 11.06.2024 на предварительный просмотр на кафедру (при наличии такой процедуры). Результат предварительной защиты выпускной квалификационной работы отражается в специальном Акте комиссии, назначаемой кафедрой.
3. Представить готовую выпускную квалификационную работу в срок не позднее 19.06.2024 на подпись руководителю.
4. Представить выпускную квалификационную работу на рецензию.
5. Представить выпускную квалификационную работу на подпись заведующему кафедрой.
6. Передать на кафедру анкетные данные консультанта выпускной квалификационной работы и рецензента (на специальном бланке), согласие на обработку персональных данных.

АННОТАЦИЯ

Пояснительная записка 71 с., 36 рис., 6 табл., 17 источников.

ПРОГНОЗИРОВАНИЕ ЦЕН АКЦИЙ, НЕЙРОСЕТИ, АНАЛИЗ ТОНАЛЬНОСТИ, BERT, LSTM, ПРОГРАММНОЕ ОБЕСПЕЧЕНИЕ

Цель работы: разработать программное обеспечение, позволяющее проводить анализ воздействия информации, распространяемой в СМИ, на цены акций компаний и прогнозировать их.

Объектом исследования выпускной квалификационной работы является динамика котировок акций и её взаимосвязь с тональной составляющей новостей о компаниях. Предметом исследования выпускной квалификационной работы являются методы анализа влияния тональной составляющей новостных сообщений на котировки акций и их прогнозирование.

На основе анализа предметной области было установлено, что выбранная тема является актуальной и требует дальнейшего развития. Разработан алгоритм работы системы, способной прогнозировать котировки акций. Собраны исходные данные: новости по компаниям (97 572 записи), а также котировки акций для каждой компании за 2014 – 2024 года. Весь объем текстовых данных предобработан с помощью алгоритмов лемматизации, а также встроенных Python функций. На основе сентиментальной составляющей каждого дня, а также информации о котировках акций обучены 49 моделей нейросетей. В ходе проведенного вычислительного эксперимента выявлено влияние тональной составляющей на котировки. Разработано программное обеспечение, позволяющее прогнозировать цены акций.

ANNOTATION

Explanatory note 71 pages, 36 figures, 6 tables, 17 sources.

STOCK PRICE FORECASTING, NEURAL NETWORKS, SENTIMENT ANALYSIS, BERT, LSTM, SOFTWARE

The purpose of the work is to develop software that allows analyzing the impact of information disseminated in the media on the share prices of companies and predicting them.

The object of study of the final qualification work is the dynamics of stock prices and its relationship with the tonal component of news about companies. The subject of the research of the final qualifying work is the methods of analyzing the influence of the tonal component of news reports on stock quotes and their forecasting.

Based on the analysis of the subject area, it was found that the chosen topic is relevant and requires further development. An algorithm for the operation of a system capable of predicting stock quotes has been developed. The initial data is collected: news on companies (97,572 records), as well as stock quotes for each company for 2014-2024. The entire volume of text data is preprocessed using lemmatization algorithms, as well as built-in Python functions. 49 neural network models were trained based on the sentimental component of each day, as well as information about stock quotes. During the conducted computational experiment, the influence of the tonal component on quotes was revealed. Software has been developed to predict stock prices.

Содержание

Введение	7
1 Аналитическая часть	9
1.1 Исследование и анализ предметной области.....	9
1.2 Анализ моделей, методов и программных продуктов для решения подобных задач	18
1.3 Постановка и формализация задачи на разработку	28
2 Проектная часть.....	33
2.1 Разработка методов и алгоритмов для решения поставленной задачи ...	33
2.2 Проектирование моделей базы данных.....	35
2.3 Проектирование программного обеспечения.....	38
2.4 Вычислительные эксперименты и анализ их результатов.....	58
Заключение.....	68
Список литературы.....	70

3221.103587.000 ПЗ

Изм.	Лист	№ докум.	Подпись	Дата	Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций.	Лит.	Лист	Листов
Разраб.		Семенов К.С.		19.06				
Провер.		Прокудина Е.И.		19.06			6	71
Консульт.		Прокудина Е.И.		19.06				
Н. Контр.		Воробьева Г.Р.		19.06				
Утверд.		Шахматова Г.Р.		19.06				
						ФГБОУ ВО. УУНиТ, КАИД-212М		

Введение

В современном мире компьютеры играют все более важную роль в повседневной жизни, а большинство информации сохраняется в электронном формате, что значительно облегчает ее хранение, доступ и обработку. Несмотря на цифровой формат, анализ многих данных вызывает определенные трудности.

Различают следующие типы данных: структурированные, частично структурированные и неструктурированные. Структурированные данные характеризуются определенной организацией и легкостью в обработке, например, базы данных. Частично структурированные данные, включают такие элементы, как электронная почта и файлы разметки (например, HTML, XML). Не структурированные данные представляют собой примерно 80% информации и вызывают сложности в извлечении и поиске нужной информации, требуя применения специализированных методов и алгоритмов обработки.

Интеллектуальный анализ текста (Text Mining) играет важную роль в обработке таких данных. Этот процесс объединяет несколько дисциплин, включая обработку веб-данных, информационный поиск, компьютерную лингвистику и обработку естественного языка. В сравнении с анализом структурированных данных, интеллектуальный анализ текста имеет большее значение, поскольку большая часть информации сохраняется в текстовом формате, и, следовательно, требует более сложных подходов для обработки.

Анализ новостей имеет широкий спектр практических применений, включая финансовые рынки, маркетинг, мониторинг общественного мнения и прогнозирование событий.

Современная финансовая среда предполагает, что инвесторы имеют доступ к разнообразной информации о компаниях, включая новости, финансовые отчеты, аналитические обзоры и другие материалы. Эта информация является ключевым фактором в процессе принятия инвестиционных решений, поскольку она может влиять на оценку рисков и потенциальной доходности компаний.

					3221.103587.000 ПЗ	Лист
						7
Изм.	Лист	№ Документа	Подпись	Дата		

Инвесторы, имея доступ к актуальной и релевантной информации, могут более точно оценить финансовое состояние компании, ее перспективы на рынке, возможные риски и потенциальную доходность. Это позволяет принимать более обоснованные инвестиционные решения и минимизировать финансовые риски.

В связи с этим, сегодня большое внимание уделяется изучению взаимосвязи между информацией, доступной инвесторам через СМИ, и котировками компаний. Анализ этой взаимосвязи позволяет понять, какие новости и события могут повлиять на цену акций компании, ее капитализацию и инвестиционную привлекательность.

Таким образом, доступ к информации играет критическую роль в современной финансовой среде, и инвесторы активно используют ее для принятия обоснованных инвестиционных решений.

Методы машинного обучения позволяют эффективно извлекать, классифицировать и анализировать информацию из СМИ для выявления связей между новостными сюжетами и рыночной динамикой.

					3221.103587.000 ПЗ	Лист
						8
Изм.	Лист	№ Документа	Подпись	Дата		

1 Аналитическая часть

1.1 Исследование и анализ предметной области

Разработка программного обеспечения для анализа влияния информации в СМИ на цены акций компаний с использованием нейросетей представляет собой важную область исследований для финансовых организаций и инвесторов. Нейросети могут использоваться для обработки и анализа большого объема данных, что позволяет прогнозировать и предсказывать рыночные тенденции с высокой точностью.

Основной задачей такого программного обеспечения является выявление связей между новостями, публикуемыми в СМИ, и изменениями в рыночной ситуации. Нейросети могут быть обучены на большом объеме данных, включая тексты статей, фото, видео и социальные медиа, для выявления паттернов и трендов.

Преимущества использования нейросетей в данном контексте включают встроенную способность к извлечению признаков и обработке неструктурированных данных, а также способность к обучению на большом объеме информации без явного программирования.

Однако, следует отметить, что нейросети требуют больших объемов данных для обучения и могут быть сложны в интерпретации результатов. Также важно учитывать этические и юридические аспекты использования данных из масс-медиа для принятия инвестиционных решений.

В целом, разработка такого программного обеспечения может быть мощным инструментом для принятия обоснованных инвестиционных решений, учитывающих широкий спектр факторов и событий.

Предметная область представляет собой комплексное исследование, сочетающее в себе элементы финансовой аналитики, информационных наук, искусственного интеллекта и программной разработки.

					3221.103587.000 ПЗ	Лист
						9
Изм.	Лист	№ Документа	Подпись	Дата		

Данная тема актуальна в современном мире, где информация становится ключевым ресурсом для принятия инвестиционных решений. СМИ играют значительную роль в формировании представлений инвесторов о компаниях, рынке ценных бумаг, макроэкономических событиях и т.д. Однако не всегда информация, представленная в СМИ, является объективной и достоверной, что может влиять на риск и доходность инвестиций.

Анализ влияния информации в СМИ требует разработки специализированного программного обеспечения, которое будет уметь собирать, анализировать и интерпретировать данные из различных источников (новостных сайтов, социальных сетей, форумов и т.д.), а также проводить статистический анализ и прогнозирование.

Программное обеспечение должно иметь функционал для определения влияния конкретных новостей и медиа-событий на изменение цен на рынке ценных бумаг, а также оценки рисков и доходности инвестиций. Это может включать в себя разработку алгоритмов машинного обучения для выявления паттернов и трендов в информационных потоках, а также интеграцию с финансовыми данными и индикаторами.

Такой анализ позволит инвесторам и трейдерам принимать обоснованные решения, учитывая влияние информации в СМИ на финансовые рынки. Также это способствует более глубокому пониманию динамики рынка и повышению эффективности инвестиционной стратегии.

Для решения поставленных задач необходимо использовать методы анализа текстов из различных источников СМИ с использованием методов обработки естественного языка, что позволит выделить актуальные темы и определить тональность информации. Этот подход позволит извлечь значимую информацию о компаниях из новостных материалов, аналитических обзоров, интервью и других источников, которые влияют на рыночные параметры.

Также необходимо использовать статистический анализ данных финансовых рынков для выявления корреляций между опубликованной информацией в СМИ и

рыночными показателями компаний. Это включает в себя проведение корреляционного анализа между временными рядами финансовых данных и параметрами новостной информации, а также оценку влияния различных событий на изменения котировок акций, объемов торгов и других финансовых показателей.

Для обработки больших объемов информации из СМИ необходимо применить методы машинного обучения, такие как классификация текстов, кластеризация новостных статей для выявления тематических групп, анализ сентимента для оценки тональности информации либо другие методы, которые позволят эффективно обрабатывать и анализировать массу данных из различных источников. Это поможет выявить взаимосвязь между информацией в СМИ и динамикой рыночных параметров компаний, а также углубить понимание воздействия новостей и медийной активности на поведение инвесторов и рыночную реакцию.

Таким образом, изучение влияния информации, представленной в СМИ, представляет большой интерес, поскольку может помочь инвесторам и управляющим портфелями принимать более обоснованные инвестиционные решения. Кроме того, данное исследование имеет практическую значимость, поскольку может помочь компаниям понять, как их известность влияет на их финансовые показатели.

1.1.1 Финансовые определения

Финансовый рынок представляет собой совокупность инструментов и экономических отношений между участниками, которые связаны с созданием, поддержанием и обращением капитала. Этот термин является довольно абстрактным, и под ним часто подразумеваются более конкретные рынки, такие как:

- рынок купонных и бескупонных облигаций;
- фондовый рынок (рынок акций);

					3221.103587.000 ПЗ	Лист
						11
Изм.	Лист	№ Документа	Подпись	Дата		

- валютный рынок.

Несмотря на выделение отдельных составляющих, каждый из этих рынков является частью единой системы, в которой финансы перемещаются между всеми конкретными рынками.

Каждый из финансовых рынков служит посредником между первоначальными владельцами финансов и их конечными пользователями. Если рынок основан на финансах как на капитале, он называется фондовым рынком и выступает в качестве составной части всего финансового рынка.

В России финансовые рынки функционируют под влиянием ряда специфических характеристик:

- Инвестиции в экономику страны. Это один из ключевых факторов, определяющих развитие финансовых рынков. Инвестиции способствуют росту экономики и созданию новых рабочих мест, что, в свою очередь, влияет на спрос и предложение на финансовых рынках.

- Международные рынки и тенденции глобализации. Россия является частью мировой финансовой системы, и её рынки подвержены влиянию глобальных тенденций. Это может проявляться в виде колебаний валютных курсов, изменения процентных ставок и других макроэкономических показателей.

- Современные компьютерные технологии. Развитие информационных технологий оказывает значительное влияние на финансовые рынки. С одной стороны, это упрощает доступ к информации и снижает издержки, связанные с операциями на рынке. С другой стороны, это создаёт новые риски, связанные с кибербезопасностью и защитой данных.

- Уровень компьютерной и информационной развитости участников рынков. От этого зависит скорость и эффективность проведения операций на финансовом рынке, а также уровень доверия между участниками.

Финансовый рынок может быть классифицирован по различным признакам:

- По стадиям обращения ценных бумаг:

					3221.103587.000 ПЗ	Лист
						12
Изм.	Лист	№ Документа	Подпись	Дата		

- Первичный рынок – рынок, на котором происходит первичное размещение ценных бумаг.
- Вторичный рынок – рынок, где обращаются ранее выпущенные ценные бумаги.
- По степени организованности:
 - Организованный рынок – это рынок, который функционирует по определённым правилам и стандартам. Он включает в себя биржи и другие торговые площадки.
 - Неорганизованный рынок – это рынок, на котором сделки заключаются вне организованных площадок.
- По месту торговли:
 - Биржевой рынок – торговля ценными бумагами осуществляется на фондовых биржах.
 - Внебиржевой рынок – сделки совершаются вне бирж, например, через дилеров или брокеров.
- По типу торговли:
 - Традиционный рынок – операции проводятся в режиме реального времени с использованием торговых терминалов.
 - Компьютеризированный рынок – торги осуществляются с помощью электронных систем, таких как интернет-трейдинг.
- По способу исполнения сделок:
 - Кассовый рынок – расчёты по сделкам производятся немедленно.
 - Срочный рынок – исполнение сделок откладывается на определённый срок.

Участники рынка ценных бумаг – это физические лица или компании, которые участвуют в операциях с ценными бумагами, обеспечивая их оборот и расчёты по ним.

Основные участники рынка – эмитенты, выпускающие акции или облигации для привлечения финансирования или размещения свободных денежных средств.

					3221.103587.000 ПЗ	Лист
						13
Изм.	Лист	№ Документа	Подпись	Дата		

Эмитентами могут быть государство, субъекты государства или коммерческие предприятия. На первичном рынке цель эмитентов – разместить запланированный транш по максимальной цене.

Инвестор – это лицо, которое заинтересовано во вложении капитала в ценные бумаги. Цель инвесторов – максимально выгодно приобрести ценные бумаги наиболее перспективных компаний. [2]

1.1.2 Литературный обзор

За последние несколько десятилетий стало проводиться все больше исследований на тему прогнозирования цен на акции, поскольку фондовый рынок продолжает расширяться. В этих исследованиях делается попытка проанализировать и спрогнозировать колебания цен на акции. Цены на акции отличаются высокой динамичностью, нелинейностью и высокой степенью зашумленности. На цену отдельных акций влияют различные факторы, включая мировую экономику, политические события, политику правительства, природные и техногенные катастрофы, поведение инвесторов и другие факторы. Это делает прогнозирование временных рядов сложной задачей.

Li, Bu & Wu (2017) и Liu и др. (2017) [2] описали некоторые исследования фондового рынка, основанные на теории случайных блужданий и гипотезе эффективного рынка. Эти исследования показали, что колебания цен на акции носят случайный характер и не поддаются прогнозированию. Согласно гипотезе эффективного рынка, на цены акций влияют новости, а не текущие или прошлые цены, поскольку новости непредсказуемы. Это означает, что цены на акции следуют случайной схеме, и их трудно предсказать с точностью более 50%. Однако более поздние исследования показали, что рыночная цена акций не является полностью случайной и в определенной степени может быть спрогнозирована.

Shah, Isah & Zulkernine (2019) и Selvin и др. (2017) [3] провели исследование фондового рынка и попытались предсказать цены на акции. Они использовали два

широко используемых метода: фундаментальный анализ и технический анализ. Фундаментальный анализ – это инвестиционный подход, который оценивает стоимость акций на основе профиля компании, перспектив отрасли, политических и экономических факторов, а также данных новостей и социальных сетей. Эта информация, как правило, неструктурирована и лучше всего подходит для долгосрочных прогнозов. Технический анализ, с другой стороны, пытается использовать исторические курсы акций для прогнозирования будущих тенденций. Он включает в себя регистрацию ежедневных колебаний цен в виде графиков и определение оптимальных точек покупки и продажи на основе наблюдаемых изменений. Обычно используемые алгоритмы при таком подходе включают К-линии, скользящие средние и индекс относительной силы, которые подходят для краткосрочных прогнозов.

Обзор литературы, проведенный Shah, Isah & Zulkernine (2019) [4] и Bustos & Pomares-Quimbaya (2020) [5], показал, что технический анализ является одним из наиболее часто используемых методов прогнозирования фондового рынка, и он широко изучался и использовался в качестве сигнала о том, когда покупать или продавать акции. Однако некоторые исследования показали, что доходность, получаемая от торговых стратегий, основанных на техническом анализе, на самом деле ограничена. Фундаментальный анализ редко использовался в традиционных исследованиях из-за сложности построения моделей на основе соответствующей информации. Тем не менее, с развитием обработки естественного языка и текстовой аналитики в некоторых недавних исследованиях была проанализирована неструктурированная информация, связанная с запасами, для повышения точности прогнозирования. Эта информация может включать официальные документы, финансовые новости и сообщения в социальных сетях.

Благодаря быстрому развитию искусственного интеллекта, Bustos & Pomares-Quimbaya (2020) [5] и Nelson, Pereira & de Oliveira (2017) [6] достигли многообещающих результатов, используя методы опорных векторов (SVM) и искусственные нейронные сети (ANN) для прогнозирования фондового рынка.

SVM, инструмент машинного обучения, может быть применен для решения задач классификации и регрессии. Его также можно назвать регрессией с опорными векторами (SVR), которая определяет гиперплоскость в пространствах объектов большой размерности для точного прогнозирования распределения данных.

Xia, Liu и Chen (2013) [7] использовали SVR для разработки подхода к прогнозированию запасов, основанного на регрессионной модели, использующей информацию о временных рядах за прошлые периоды, сегодняшние цены открытия, самые высокие цены, самые низкие цены, цены закрытия, объемы торгов и скорректированные цены закрытия для прогнозирования цен открытия на следующий день.

RNN часто используются наряду с другими ANN для решения задач, связанных с временными рядами, и они также являются одним из наиболее подходящих методов для прогнозирования динамических временных рядов.

Liu и др. (2017) [8] использовали RNN для прогнозирования волатильности акций и обнаружили, что точность модели RNN превосходит точность моделей MLP и SVM. Тем не менее, RNN могут испытывать проблемы с исчезновением градиента и резким ростом в течение нескольких итераций. Нейронные сети LSTM были разработаны для повышения производительности RNN в области искусственного интеллекта.

Gao, Chai & Liu (2017) [9] собрали исторические торговые данные из индекса Standard & Poor's 500 (S&P 500), охватывающие последние 20 торговых дней, в качестве входных переменных, включая цену открытия, цену закрытия, самую высокую цену, самую низкую цену, скорректированную цену и объем сделки.

Они использовали нейронную сеть LSTM в качестве модели прогнозирования и оценивали ее эффективность, используя среднюю абсолютную ошибку (MAE), среднеквадратичную ошибку (RMSE), среднюю частоту абсолютных ошибок (MSE) и среднюю абсолютную процентную ошибку (MAPE). Их подход превзошел другие методы прогнозирования.

Lee & Soo (2017) [10] объединили нейронную сеть LSTM с ANN для прогнозирования цен на тайваньские акции на основе исторических ценовых данных и финансовых новостей и обнаружили, что это уменьшает ошибку прогнозирования.

Li, Bu & Wu (2017) [2] применили сеть LSTM для прогнозирования взлетов и падений китайского индекса CSI 300, введя данные об открытии, закрытии и объеме торгов за последние десять торговых дней, достигнув точности в 78,57%.

Khare и др. (2017) [11] аналогичным образом обнаружили, что LSTM могут точно прогнозировать движение цен на акции.

Lu (2018) [12] проанализировал положительные и отрицательные оценки настроений, полученные из публикаций РТТ, и объединил исторические данные о биржевых транзакциях в качестве входных векторов для нейронной сети с долговременной кратковременной памятью (LSTM). Предложенный метод повысил точность прогнозирования цен на акции.

В своей статье Рябых А., Суржко Д., Коновалихи М. и Кольцов С. [13] представили подход STTM (Sentiment-based Topic Model), который использует тематические модели и тональные потоки тем для анализа текстовых данных с целью прогнозирования направления движения финансового рынка.

На основе обработанных текстовых данных они генерируют вероятностные темы. Тематическая модель позволяет выделить основные темы в тексте и определить их вероятность появления. Тональность темы определяется функцией оценки регрессии или метрикой близости временных рядов. Это позволяет оценить эмоциональную окраску каждой темы и её влияние на рынок.

Затем в работе тональный поток тем вычисляется как произведение тональностей тем и тематических потоков для каждого момента времени. Это даёт возможность оценить общую тональность всех тем в определённый период времени. Выдвинутый ими индекс STTM представляет собой общую тональность всех тем за определённый период времени и может использоваться для прогнозирования направления движения рынка.

Однако стоит отметить, что подход STTM требует тщательной настройки параметров и проверки результатов на реальных данных. Также необходимо учитывать возможные ограничения и недостатки подхода, связанные с использованием текстовых данных и их интерпретацией.

1.2 Анализ моделей, методов и программных продуктов для решения подобных задач

В данном обзоре рассмотрим существующие методы, используемые для разработки программного обеспечения задачи анализа влияния информации в СМИ на риск и доходность инвестирования в ценные бумаги.

Прогнозирование цен на акции является сложной задачей, требующей учёта множества факторов. Одним из подходов к решению этой задачи является использование новостных потоков. Новостные потоки содержат информацию о событиях, которые могут повлиять на цены акций. Анализируя эти данные, можно попытаться предсказать будущие изменения цен.

Для решения задачи прогнозирования цен на акции с использованием новостных потоков можно использовать различные модели, методы и программные продукты. Рассмотрим некоторые из них:

1.2.1 Обзор алгоритмов машинного обучения

Регрессионные модели.

Существует множество регрессионных моделей, таких как линейная регрессия, логистическая регрессия, деревья решений, нейронные сети и другие. Каждая модель имеет свои преимущества и недостатки, поэтому важно выбрать модель, которая наилучшим образом соответствует данным и целям исследования.

					3221.103587.000 ПЗ	Лист
						18
Изм.	Лист	№ Документа	Подпись	Дата		

Линейная регрессия – это статистический метод, который используется для моделирования взаимосвязи между двумя или более переменными. В контексте предсказания цен акций линейная регрессия может быть использована для определения зависимости между ценой акции и различными факторами, такими как новости, макроэкономические показатели и прошлые цены акций.

В линейной регрессии предполагается, что существует линейная зависимость между зависимой переменной (в данном случае, ценой акции) и независимыми переменными (например, новостями, макроэкономическими показателями и прошлыми ценами акций). Эта зависимость может быть выражена следующей формулой (1):

$$y = a + b \cdot x, \quad (1)$$

где y – зависимая переменная (цена акции), a – свободный член, b – коэффициент регрессии, а x – независимая переменная (например, новость или макроэкономический показатель). [14]

Линейная регрессия является простым и широко используемым методом для анализа данных. Однако она имеет некоторые ограничения. Например, она предполагает, что зависимость между переменными является линейной, что может не всегда соответствовать действительности. Кроме того, линейная регрессия чувствительна к выбросам, которые могут исказить результаты. Поэтому при использовании линейной регрессии для предсказания цен акций необходимо учитывать эти ограничения.

Логистическая регрессия – это тип регрессионного анализа, который подходит, когда зависимая переменная принимает только два возможных значения (т.е. дихотомическое или бинарное). Этот метод часто имеет место при прогнозировании событий, когда есть только два исхода: событие произойдет (обозначается как 1) и не произойдет (обозначается как 0).




Рисунок 1.1 – Пример использования линейной регрессии

Логистическая регрессия имеет некоторое сходство с линейной регрессией, поскольку она также предполагает определение значений коэффициентов для входных переменных. Однако результаты логистической регрессии преобразуются с использованием нелинейной или логистической функции, а не линейной. Как и другие методы регрессионного анализа, такая регрессия может использоваться для прогнозирования. Она используется для анализа данных и определения взаимосвязи между одной двоичной зависимой переменной и одной или несколькими независимыми переменными, которые могут быть номинальными, порядковыми или интервальными по своей природе.

Решающие деревья – это метод машинного обучения, который используется для решения задач классификации и регрессии. В контексте предсказания цен акций решающие деревья могут быть использованы для создания правил, которые определяют, как будет изменяться цена акции в зависимости от различных факторов.




Рисунок 1.2 – Пример использования логистической регрессии

Решающее дерево представляет собой иерархическую структуру, состоящую из узлов и листьев. Узлы представляют собой вопросы или условия, а листья – результаты или прогнозы. Процесс построения решающего дерева начинается с корневого узла, который содержит все данные. Затем данные разделяются на подмножества на основе вопросов или условий, заданных в узлах. Этот процесс повторяется до тех пор, пока не будут достигнуты листья, содержащие прогнозы или результаты. [15]

Выбор модели зависит от конкретных целей исследования и доступных данных. Например, если необходимо предсказать вероятность изменения цены акции, то логистическая регрессия может быть более подходящей. Если же требуется создать правила для определения изменения цены на основе новостей, то деревья решений могут быть предпочтительнее.




Рисунок 1.3 – Пример использования решающих деревьев

Нейронные сети.

В контексте предсказания цен акций нейронные сети могут быть использованы для создания моделей, которые учитывают множество факторов, таких как новости, макроэкономические показатели и прошлые цены акций. Эти модели могут быть обучены на больших объёмах данных и способны давать точные прогнозы будущих цен.

Однако, несмотря на свою мощь, нейронные сети также имеют некоторые ограничения. Например, они могут быть чувствительны к переобучению, если модель слишком сильно адаптируется к обучающим данным. Поэтому важно тщательно выбирать параметры модели и проверять её на тестовом наборе данных перед использованием для принятия решений. Кроме того, интерпретация результатов нейронной сети может быть сложной задачей, поскольку она представляет собой «чёрный ящик», который не всегда позволяет понять, как именно были получены результаты. [16]

Тем не менее, при правильном использовании нейронные сети могут стать мощным инструментом для прогнозирования цен акций. Они позволяют учитывать

сложные зависимости между переменными и дают возможность получать точные прогнозы на основе большого объёма данных. Однако, прежде чем использовать нейронные сети для принятия инвестиционных решений, необходимо тщательно изучить их возможности и ограничения, а также провести тестирование на исторических данных.

Для задачи предсказания цен акций можно использовать различные архитектуры нейронных сетей:

Рекуррентные нейронные сети (RNN) – это тип нейронной сети, который может обрабатывать последовательные данные, такие как временные ряды. RNN могут быть использованы для анализа временных рядов цен акций и прогнозирования будущих значений.




Рисунок 1.4 – Архитектура рекуррентной нейронной сети

Свёрточные нейронные сети (CNN) – это ещё один тип нейронной сети, который хорошо подходит для обработки изображений. Однако CNN также могут быть адаптированы для работы с временными рядами, такими как цены акций. CNN могут использоваться для выявления паттернов в данных о ценах акций и прогнозирования их будущих значений.




Рисунок 1.5 – Архитектура свёрточной нейронной сети

Нейронные сети с долгой краткосрочной памятью (LSTM) – это разновидность рекуррентных нейронных сетей, которая может эффективно обрабатывать долгосрочные зависимости в данных. LSTM могут быть полезны для анализа долгосрочных тенденций в ценах акций.




Рисунок 1.6 – Архитектура сети с ячейками LSTM

Генеративно-сопоставительные сети (GAN) – это архитектура нейронных сетей, состоящая из двух подсетей: генератора и дискриминатора. Генератор создаёт новые данные, а дискриминатор пытается отличить эти данные от реальных. GAN

могут быть использованы для создания синтетических данных о ценах акций, которые могут быть использованы для обучения других моделей.




Рисунок 1.7 – Архитектура генеративно-состязательной нейронной сети

Выбор конкретной архитектуры зависит от данных, целей и ресурсов. Если используется большой объём данных, то нейронные сети с ячейками LSTM или генеративно-состязательные сети могут дать наилучшие результаты. Иначе же более подходящими могут быть рекуррентные или свёрточные нейронные сети [17].

1.2.2 Обзор методов обработки естественного языка (NLP)

Лемматизация.

Это метод приведения текста к его словарной форме (лемме). Лемма – это базовая форма слова, которая используется в словарях. Например, для глагола «бегу» леммой будет «бежать», а для существительного «стола» – «стол». В отличие от стемминга (обрезания суффикса слов), лемматизация является более лояльным методом обработки слов, так как она возвращает первоначальную форму слова.

Этот метод прост и эффективен, но он имеет некоторые недостатки. Во-первых, он может не работать с некоторыми словами, которые не имеют лемм в словаре. Во-вторых, он может изменить значение слова, если оно имеет несколько лемм.

Например, слово «бегут» может иметь две леммы: «бежать» и «бег». Если программа использует первую лемму, она изменит значение слова с множественного числа на единственное. Это может привести к ошибкам в обработке текста.

Чтобы избежать этих проблем, можно использовать более сложные методы лемматизации. Эти методы учитывают контекст слова и могут выбирать правильную лемму даже для слов, которых нет в словаре.

Для обработки русских слов существует множество пакетов, которые выполняют данную задачу: Rymystem, Rymorphy, Томита-парсер, Яндекс-спеллер и другие.

Анализ тональности.

Сентимент-модели – это модели, которые используются для анализа тональности текста. Они позволяют определить, является ли текст положительным, отрицательным или нейтральным.

Явным примером для определения тональности текста является модель BERT (Bidirectional Encoder Representations from Transformers) – это модель машинного обучения, которая используется для обработки естественного языка. Она была разработана компанией Google в 2018 году и с тех пор стала одной из самых популярных моделей в этой области.

BERT основана на архитектуре трансформеров, которые представляют собой тип нейронных сетей, способных обрабатывать последовательности данных. Трансформеры состоят из двух основных компонентов: кодировщика и декодировщика. Кодировщик преобразует входные данные в скрытые представления, а декодировщик использует эти представления для генерации выходных данных.




Рисунок 1.8 – Архитектура модели BERT

В случае BERT кодировщик является двунаправленным, то есть он обрабатывает входные данные как слева направо, так и справа налево. Это позволяет модели учитывать контекст слов во входных данных и лучше понимать их смысл.

Для обучения BERT используются два метода:

Маскированный язык моделирования (MLM): В этом методе часть слов во входных данных маскируется, и модель должна предсказать эти слова на основе контекста.

Предсказание следующего предложения (NSP): В этом методе модель обучается предсказывать, какое предложение следует за данным предложением во входном тексте.

Эти методы позволяют модели научиться понимать контекст слов и предложений, что делает её полезной для различных задач обработки естественного языка, таких как классификация текста, ответы на вопросы и перевод.

1.2.3 Обзор программных продуктов

Существует множество программных продуктов, которые можно использовать для анализа новостных данных и прогнозирования цен акций. Рассмотрим некоторые из них.

Python: является популярным языком программирования, который широко используется для машинного обучения и анализа данных. Также в нём существует набор библиотек Python, таких как pandas, numpy и scikit-learn, которые можно использовать для создания моделей прогнозирования цен акций.

R: является ещё одним популярным языком программирования для статистического анализа и машинного обучения. Существуют пакеты R, такие как tidyverse и caret, которые можно использовать для построения моделей прогнозирования цен акций.

Специализированные платформы: существуют также специализированные платформы, предназначенные для анализа финансовых данных, такие как Quandl, Alpha Vantage и Yahoo Finance. Эти платформы предоставляют доступ к финансовым данным, таким как цены акций, объёмы торгов и новостные данные.

Выбор конкретной модели, метода и программного продукта зависит от конкретных требований и ограничений задачи. Важно провести тщательное исследование и тестирование различных подходов, чтобы определить наиболее эффективный метод прогнозирования для конкретной ситуации.

1.3 Постановка и формализация задачи на разработку

На рисунках 1.9 и 1.10 представлены постановка задачи в виде контекстной диаграммы и её декомпозиция, соответственно.

					3221.103587.000 ПЗ	Лист
						28
Изм.	Лист	№ Документа	Подпись	Дата		




Рисунок 1.9 – Постановка задачи: контекстная диаграмма




Рисунок 1.10 – Структура решения




Рисунок 1.11 – Структура решения блока «Создание нейронных сетей»

Цель проводимого исследования заключается в разработке ПО, способного проводить анализ воздействия информации, распространяемой в средствах массовой информации, на цены акций компаний на финансовых рынках и прогнозировать их.

Реализация данной цели включает в себя решение целого ряда задач, направленных на полноценное исследование влияния информации в СМИ на финансовые рынки и компании.

Задачи:

1. Провести аналитический обзор предметной области;
2. Составить общую методику работы создаваемой системы прогнозирования;
3. Провести сбор данных, получить новостные данные, а также котировки;
4. Провести предобработку текстовых данных новостей, привести в вид, понятный для модели нейронной сети;
5. Создать и обучить модели нейронных сетей, способных предсказывать будущую цену акции, на основе прошлых данных котировок и новостного потока;
6. Провести вычислительный эксперимент на основе полученных моделей нейросетей.
7. Реализовать программное обеспечение для выдачи прогноза, основанное на полученных моделях нейронных сетей.

Таким образом, исследование данных задач позволит глубже понять механизмы взаимодействия информации, распространяемой в СМИ, с финансовыми рынками и компаниями, а также позволит инвесторам принимать более правильные решения.

					3221.103587.000 ПЗ	Лист
						32
Изм.	Лист	№ Документа	Подпись	Дата		

2 Проектная часть

Набор компаний для создания программного решения был выбран на основе индекса МосБиржи, а также некоторых популярных компаний, которые не входят туда.

Таким образом был сформирован список из 49 российских компаний: Афк Система, Аэрофлот, Русагро, Алроса, Московский Кредитный Банк, Северсталь, Эн+, Х5, Совкомфлот, Газпром, Глобалтранс, Норникель, Русгидро, Интер РАО, Лукойл, Ммк, Магнит, Мосэнерго, Мечел, Мтс, Нлмк, Новатэк, Озон, Фосагро, Пик, Полнос, Полиметал, Позитив, Роснефть, Ростелеком, Русал, Сбер, Селигдар, Сегежа, Самолет, Сургутнефтегаз, Татнефть, Тинькофф, Транснефть, Юнипро, Вконтакте, Втб, Яндекс, Фск Еэс ОАО, Qiwi, Тмк, Акрон, Мать и дитя, Ютэйр.

2.1 Разработка методов и алгоритмов для решения поставленной задачи

Для решения поставленной задачи предлагается использовать алгоритм, представленный на рисунке 2.1 ниже.




Рисунок 2.1 – Общая методика работы системы

В начале работы необходимо провести сбор данных новостей компаний. Для этого необходимо разработать программу, позволяющую автоматически собирать новостные публикации, обеспечивающую бесперебойную работу. В качестве информационного ресурса был выбран сайт finam.ru, так как в этом портале есть возможность собирать данные, разделенные по компаниям, и не имеющие временных ограничений по дате публикации.

2.1.1 Обработка текстовых данных новостей

Обработка текста новостей является неотъемлемой частью работы, поскольку неструктурированные данные при анализе не позволят провести их правильную интерпретацию.

Для того чтобы сделать это, сначала необходимо привести весь текст к нижнему регистру. Затем убираются специальные символы, то есть знаки пунктуации, а также числа. Так как работа основана на корпусе русских новостей, то латинские символы будут только затруднять понимание текста, поэтому от них тоже необходимо избавиться.

В большинстве текстов, для их правильного понимания человеком, присутствуют различные местоимения, предлоги и прочие части речи, которые не несут в себе определенной смысловой нагрузки для машины, поэтому на основе собранных новостей необходимо создать список стоп-слов, в который будут включены такие слова. На основании полученного набора, из каждого текстового представления данных необходимо вычлениить эти слова.

После того как были выполнены ранее описанные действия, каждое слово необходимо привести к его нормальному виду используя алгоритм лемматизации.

Также новости часто состоят из слов, которые по тем или иным причинам повторяются в тексте не один раз. Для правильного определения тональности поступающего текста, леммы повторов будут создавать только лишний шум, поэтому от них также необходимо избавляться.

					3221.103587.000 ПЗ	Лист
						34
Изм.	Лист	№ Документа	Подпись	Дата		

Далее, для того, чтоб подготовить данные для обучения нейросети, необходимо объединить новости одного дня в единый набор, и вычислить тональность полученного текста для каждого дня. Этот параметр будет определять, как прошёл день для компании на основе новостей – позитивно или же негативно. Каждому дню присваивается своё значение тональности, а также цена котировки на этот день. Таким образом составляется дата сет, для того чтобы нейронную сеть было возможно обучить.

2.2 Проектирование моделей базы данных

В данной главе рассмотрим базу данных, используемую в разработке программного обеспечения. Для реализации этой задачи была выбрана система управления базами данных PostgreSQL 16.

Выбор СУБД является важным этапом разработки ПО. PostgreSQL обладает рядом преимуществ, которые делают его подходящим выбором для данного проекта. Среди них:

- Масштабируемость: PostgreSQL может обрабатывать большие объёмы данных и масштабироваться по мере роста объёма данных. Это важно для прогнозирования цен на акции, где требуется обработка большого количества данных.
- Безопасность: PostgreSQL обеспечивает высокий уровень безопасности данных благодаря поддержке шифрования, аутентификации и авторизации.
- Простота: синтаксис языка программирования, используемый в PostgreSQL имеет большие сходства с языком SQL, что делает его простым в использовании

Для связи с базы данных и исполняющих Python файлов используется библиотека psycopg2. Она предоставляет простой и удобный способ взаимодействия с СУБД PostgreSQL из Python.

					3221.103587.000 ПЗ	Лист
						35
Изм.	Лист	№ Документа	Подпись	Дата		

2.2.1 Концептуальная модель базы данных

Концептуальная модель базы данных — это абстрактное представление предметной области, которое описывает основные сущности и связи между ними. Она не зависит от конкретной СУБД и её особенностей.

В используемой базе данных присутствуют 5 связанных между собой сущностей (Рисунок 2.2):

- «Новости» - таблицы с новостями;
- «Котировки» - таблицы с записями котировок;
- «Предобработанные данные» - предобработанные текстовые новости;
- «Тональности дней» - векторные представления тональности новостных дней;
- «Обучающие данные» - объединенные данные, используемые для обучения нейросетей.




Рисунок 2.2 – Концептуальная модель базы данных

2.2.2 Логическая модель базы данных

Логическая модель базы данных — это абстрактное представление структуры данных, которое описывает сущности и связи между ними без учёта конкретных деталей реализации. Логическая модель служит связующим звеном между концептуальной моделью предметной области и физической моделью базы данных (Рисунок 2.3).




Рисунок 2.3 – Логическая модель базы данных

2.2.3 Администрирование базы данных

Администрирование базы данных включает в себя управление пользователями, правами доступа, резервным копированием и восстановлением данных. Для администрирования PostgreSQL используется pgAdmin4 — графический интерфейс, предоставляющий удобный доступ к функциям управления базой.

2.3 Проектирование программного обеспечения

Всего в программе присутствует 15 программных файлов (модулей), каждый из которых отвечает за свою часть работы (Рисунок 2.4).

Каждый модуль выполняет определённую функцию, которая необходима для корректной работы всей программы. Модули могут взаимодействовать друг с другом, обмениваясь данными посредством связи с базой данных.

- `stocks_parse_init.py` отвечает за загрузку котировок с сайта investing.com и выгрузку полученных значений в базу данных;
- `news_parse_init.py` отвечает за скачивание новостей с сайта finam.ru и выгрузку полученных новостей в базу данных;
- `text_preprocessor_init.py` выполняет предобработку полученных новостей и их выгрузку в базу данных;
- `sentiment_analyze_init.py` выполняет тональный анализ предобработанных на прошлом шаге данных и выгрузку полученных векторов в базу данных;
- `data_prepare_init.py` отвечает за объединение котировок и векторов тональности новостей, полученных на прошлом шаге;




Рисунок 2.4 – Диаграмма компонентов программных файлов

- `traint_init.py` отвечает за создание нейросетей на основе данных полученных на прошлом шаге, а также выгрузку моделей, а также графика процесса обучения в рабочую директорию;
- `predict_init.py` проводит процесс прогнозирования используя модели, полученные на прошлом шаге, а также выгрузку результатов и их описание;
- `flow.py` отвечает за создание ориентированного ациклического графа задач, состоящего из файлов `stocks_parse.py`, `news_parse.py`, `text_preprocessor.py`, `sentiment_analyze.py`, `data_prepare.py` и `predict.py`, видоизменных под выполнение ежедневного процесса сбора, трансформации и выгрузки данных (прогноза) в базу данных;
- `telegram_bot.py` отвечает за функционирование Телеграм-бота, загрузку прогнозов из базы данных и их вывод в Телеграм в форме оповещения.

2.3.1 Сбор данных новостей

В начале программы необходимо импортировать необходимые библиотеки. Основные это Selenium, через которую будет происходить связь и сбор информации с новостного сайта, а также Pyscorg2, которая создаёт подключение к базе данных и позволяет записывать данные в заранее созданную таблицу.

Работа парсера происходит следующим образом:

1. Задается URL ссылка общего вида на страницу, с которой будет происходить сбор новостей.

Пример: <https://www.finam.ru/publications/section/companies/date/>

2. Вносится диапазон необходимых дат начала и конца, т.е. с какого числа по какое необходимо будет собирать информацию (01.01.2014 – 01.01.2024).

3. Парсер запускается и проходится по необходимому диапазону дат добавляя в конец ссылки из п.1 ту или иную последовательную дату (Рисунок 2.5).




Рисунок 2.5 – Работа парсера новостей

4. При открытии страницы сайт ограничивает показ новостей количеством 20 штук, поэтому парсер сначала нажимает кнопку «Загрузить ещё» столько раз, сколько это возможно.

5. После того как все новости выбранного дня были выведены происходит запись ссылок на каждую новость в заранее определенный список.

6. После того как ссылки на новости в определенном дне были полностью собраны происходит повтор п.3 – п.5 до того момента пока не будет достигнута конечная дата из п.2.

					3221.103587.000 ПЗ	Лист
						41
Изм.	Лист	№ Документа	Подпись	Дата		

7. Как только парсер прошел по всем датам из ранее заданного диапазона происходит непосредственный сбор информации из новостей: каждая ссылка из собранного списка последовательно открывается парсером и из новости отбираются все необходимые данные – ссылка на новость, текст заголовка, текст новости и дата выпуска новости (Рисунок 2.6). Как только данные были получены они сразу записываются в базу данных.




Рисунок 2.6 – Работа парсера новостей

8. Таким образом в базу данных за 2014 – 2024 гг. было собрано 97 572 новости.

Ниже приведена гистограмма распределения количества новостей по компаниям (Рисунок 2.7).




Рисунок 2.7 – Распределение количества новостей по компаниям

Исходя из представленного графика, самыми обсуждаемыми компаниями за последние 10 лет были: Газпром (10 938 записей), Сбербанк (8 495 записей) и Роснефть (4 857 записей).

2.3.2 Сбор данных котировок

Для того чтобы можно было определить влияние той или иной новости на цену акции компании, необходимо также иметь данные об изменениях цен на бумаги. Для этих целей создается парсер котировок цен акций компаний (Рисунок 2.8).

Принцип его работы заключается в сборе исторических данных каждой компании с сайта Investing.com. Работает он следующим образом:




Рисунок 2.8 – Работа парсера котировок

1. Заранее создается список ссылок на страницы с историческими данными котировок для каждой компании.
2. При включении парсера последовательно открывается каждая ссылка из списка, созданного в п.1.
3. При открытии страницы показываются ежедневные данные лишь за последний месяц. Поэтому парсер автоматически открывает виджет в котором задается диапазон дат, и вносит туда необходимый диапазон (01.01.2014 – 01.01.2024).

(660 записей, выпустили акции в апреле 2021 года) и Озон (766 записей, выпустили акции в ноябре 2020 года).

2.3.3 Предобработка новостей

За обработку собранных новостей отвечает программа `text_processor_init.py`. Каждая новость поступает на вход программы и проходит ряд операций.

К одной из таких относится процесс лемматизации, при котором каждое слово заменяется на его первоначальную форму. За выполнение этого шага отвечает модуль `Rymystem 3.1` от компании Яндекс. Преимуществом данного пакета является то, что он создан специально для корпуса русских слов, а также, что немаловажно, использует контекстные алгоритмы, позволяющие приводить слова к начальной форме учитывая контекст. То есть, если бы у нас был текст «Мама мыла раму» который мы бы хотели лемматизировать, то обычный алгоритм расшифровал бы его как «Мама мыло рама», а, в свою очередь, контекстный – «Мама мыть рама».

Рассмотрим алгоритм обработки текста на примере заголовка новости компании «АФК Система»: «Чистая прибыль АФК "Система" по US GAAP в 2013 году выросла на 11,1% - до \$2 млрд».

1. Текст приводится к нижнему регистру: «чистая прибыль афк "система" по us gaap в 2013 году выросла на 11,1% - до \$2 млрд»
2. Убирается вся пунктуация: «чистая прибыль афк система по us gaap в 2013 году выросла на 111 до 2 млрд»
3. Убираются все числовые символы: «чистая прибыль афк система по us gaap в году выросла на до млрд»
4. Убираются все латинские символы: «чистая прибыль афк система по в году выросла на до млрд»
5. Из слов выделяются их леммы: «чистый прибыль афк система по в год вырастать на до млрд»

6. Убираются стоп-слова из заранее созданного соответствующего списка stop-words.txt: «чистый прибыль афк система вырастать»

7. Далее убираются повторяющиеся слова.

8. Также убираются слова, которые излишне часто и крайне редко повторяются в корпусе: «чистый прибыль вырастать»

В итоге, получаем обработанный текст – «чистый прибыль вырастать», первоначально имевший вид – «Чистая прибыль АФК "Система" по US GAAP в 2013 году выросла на 11,1% - до \$2 млрд».

Таким образом из новости вычленяются самые полезные для её дальнейшего использования слова, по которым можно достоверно оценить её смысловой характер.

2.3.4 Сентиментальный анализ текста

Применение сентиментального анализа текста является одним из ключевых аспектов работы. За проведение этой процедуры отвечает файл sentiment_analyze.py.

При проведении данной операции используется нейросеть RuBERT-base-cased-sentiment, основанная на архитектуре трансформеров. Данная модель уже обучена на 351 797 русских текстах. Итогом работы данной нейросети является трехмерный вектор, компонентами которого являются следующие параметры: NEUTRAL, POSITIVE, NEGATIVE.

Рассмотрим алгоритм на примере обработанного текста компании АЛРОСА: «выручка группа включая прочий деятельность увеличиваться примерно прошлое составлять сообщаться материал алмазодобыча карат реализация запас нейтральный динамика алмазный квартал придерживаться прогноз число ювелирный качество средний технический».

					3221.103587.000 ПЗ	Лист
						47
Изм.	Лист	№ Документа	Подпись	Дата		

Для того чтобы продемонстрировать пример работы данного алгоритма на рисунках 2.10, 2.11, 2.12 приведены представления в виде облака слов для наборов наиболее встречающихся слов позитивных, негативных, а также нейтральных текстов для компании «Алроса».



Как видно из данных рисунков, наиболее часто, в новостях с позитивным уклоном, встречаются слова «высокий», «результат», «позитивный». Дни с преимущественно негативными настроениями чаще характеризуют слова: «текущий», «начало», «составлять».



Рисунок 2.11 – Word cloud для негативных текстов




Рисунок 2.12 – Word cloud для нейтральных текстов

С нейтральными текстами ситуация несколько сложнее, так как в них одинаково по количеству могут встречаться и слова из положительных наборов, и с отрицательных, а также те, по которым сложно охарактеризовать эмоциональный окрас.

2.3.5 Создание нейронных сетей

После того как все основные данные для создания и обучения нейронной сети были подготовлены, необходимо создать саму нейросеть.

Для решения поставленной задачи анализа текста отлично подойдет архитектура модели, включающая в себя ячейки LSTM. Такой выбор был сделан в связи с тем, что данный метод имеет возможность запоминать в долгосрочной перспективе данные, которые в неё вошли. Таким образом в модели будет учитываться контекст новостей.

Для начала подготовленные данные необходимо разделить на обучающую и тестовую выборки. Разделение данных производится по следующему принципу: 80% данных будут использоваться как тренировочные, а оставшиеся 20% для теста.

Для того чтобы сформировать выборки в программе существует специальная функция `CreateDataset`, которая предназначена для подготовки данных для обучения модели прогнозирования временных рядов. Эта функция принимает набор данных, целевую переменную и необязательный параметр обратного просмотра, который определяет количество предыдущих временных шагов, которые должна учитывать модель. Функция выполняет итерацию по набору данных, генерируя пары входных последовательностей и соответствующие им целевые значения.

Для каждой итерации она извлекает из набора данных окно временных шагов обратного просмотра (i) и формирует последовательность из этих значений в список обучающих данных. Соответствующее целевое значение для последнего временного шага в этом окне добавляется в список проверочных данных. Наконец, функция возвращает два массива, которые можно использовать для обучения модели. Каждая строка в списке обучающих данных содержит последовательность предыдущих наблюдений, а каждый соответствующий элемент в списке проверочных данных представляет целевое значение, которое необходимо предсказать в данный момент.

Данный алгоритм наглядно описан на рисунке 2.13. Здесь параметр n описывает параметр обратного просмотра, описанный выше.




Рисунок 2.13 – Алгоритм предсказания параметра

Таким образом обучающий набор данных в общем случае представляет из себя вектор, состоящий из n записей, каждая из которых в свою очередь состоит из четырех компонент, которые характеризуют следующие показатели: «цена открытия», «показатель позитивного настроения», «показатель негативного настроения» и «показатель нейтрального настроения». На основании этих данных модель нейронной сети должна предсказывать «цену закрытия», которая и является целевой функцией.

Архитектура нейронной сети.

Составление нейросети проводилось с помощью пакета Keras, широко используемого в машинном обучении.

В общем виде архитектура созданной модели состоит из следующих слоев, приведенных на рисунке 2.14.




Рисунок 2.14 – Архитектура нейросети

Набор слоев состоит из последовательно идущих трех слоев LSTM и Dropout, а завершается слоем Dense и Activation. Каждый слой LSTM состоит из 100 нейронов, а каждый слой Dropout имеет параметр, который определяет долю исключаемых нейронов, равный 0.6.

Таким образом, блоки LSTM принимают входные данные в виде последовательности, передают данные в слой Dropout, который используется для предотвращения переобучения модели путём случайного исключения некоторых нейронов во время обучения.

После слоя Dropout данные поступают в слой Dense. Слой Dense преобразует выходные данные последнего LSTM блока в одномерный вектор с помощью функции активации linear. Функция активации linear просто умножает входные данные на коэффициент, который определяется во время обучения модели.

Этот слой играет важную роль в преобразовании выходных данных LSTM блоков в формат, который может быть использован для дальнейшей обработки. Он также позволяет модели лучше понять структуру данных и выделить важные признаки.

Для вывода конечного результата используется слой Activation, в котором применяется функция активации tanh, которая ограничивает значения выходного вектора между -1 и 1.

Также слой Dense включает в себя параметр регуляризации, который используется для ограничения весов модели, чтобы предотвратить их чрезмерное увеличение и улучшить обобщающую способность модели. В данном случае используется L1-регуляризация с коэффициентом 0.00001.

При компиляции модели используется функция потерь MSE (Mean squared error или же средняя квадратичная ошибка), оптимизатор Adam, а также дополнительно отслеживается параметр MAE (mean absolute error или же средняя абсолютная ошибка).

2.3.6 Прогнозирование цен акций

Для того чтобы система функционировала в режиме реального времени и могла выдавать прогноз на ежедневной основе, необходимо создать ETL-процесс, а также Telegram-бота для автоматического оповещения.

ETL-процесс.

Поскольку модели нейронных сетей уже были разработаны ранее, то для того, чтобы их использовать, достаточно провести повторную процедуру предсказания на новых данных, чтобы вычислить будущее значение.

В качестве системы, реализующей данную задачу на ежедневной основе, была выбрана система управления рабочими процессами – Apache Airflow. Данное решение обладает существенными преимуществами, такими как:

- Гибкость и масштабируемость: Airflow предоставляет гибкие возможности для создания, управления и мониторинга рабочих процессов. Это позволяет легко масштабировать систему под растущие потребности.
- Поддержка различных источников данных: Airflow может интегрироваться с различными источниками данных, такими как базы данных, очереди сообщений и другие системы. Это упрощает процесс извлечения, преобразования и загрузки данных (ETL).
- Визуализация рабочих процессов: Airflow позволяет визуализировать рабочие процессы в виде диаграмм либо графов, что упрощает их понимание и анализ.
- Мониторинг и оповещение: Система предоставляет инструменты для мониторинга выполнения задач и оповещения о событиях, таких как ошибки или завершение задач.
- Параллельное выполнение задач: Airflow поддерживает параллельное выполнение задач, что ускоряет обработку больших объёмов данных.

К недостаткам этой системы можно отнести её сложность при настройке и установке, так как исходная версия данного продукта была разработана для использования в связке с операционной системой Linux или же MacOS.

Поэтому для успешной реализации этой задачи необходимо установить клиент-подсистему основанную на Linux – Ubuntu версии 22.04.3, и уже в ней разворачивать систему (Рисунок 2.15, 2.16).

```

home@DESKTOP-BRAC6VD: ~
Подсистема Windows для Linux теперь доступна в Microsoft Store.
Вы можете выполнить обновление, запустив команду "wsl.exe --update" или посетив страницу https://aka.ms/wslstorepage
При установке WSL из Microsoft Store вы сможете быстрее получать обновления для WSL.
Дополнительные сведения см. на странице https://aka.ms/wslstoreinfo

Welcome to Ubuntu 22.04.3 LTS (GNU/Linux 4.4.0-19041-Microsoft x86_64)

 * Documentation:  https://help.ubuntu.com
 * Management:    https://landscape.canonical.com
 * Support:       https://ubuntu.com/advantage

This message is shown once a day. To disable it please create the
/home/home/.hushlogin file.
home@DESKTOP-BRAC6VD:~$ source airflow_env/bin/activate
(airflow_env) home@DESKTOP-BRAC6VD:~$ airflow scheduler

[2024-06-07T18:21:26.020+0500] {task_context_logger.py:63} INFO - Task context logging is enabled
[2024-06-07T18:21:26.031+0500] {executor_loader.py:235} INFO - Loaded executor: SequentialExecutor
[2024-06-07T18:21:26.185+0500] {scheduler_job_runner.py:796} INFO - Starting the scheduler
[2024-06-07T18:21:26.186+0500] {scheduler_job_runner.py:803} INFO - Processing each file at most -1 times
[2024-06-07T18:21:26.208+0500] {manager.py:170} INFO - Launched DagfileProcessorManager with pid: 80
[2024-06-07T18:21:26.209+0500] {scheduler_job_runner.py:1595} INFO - Adopting or resetting orphaned tasks for active dag runs

[2024-06-07T18:21:26.218+0500] {settings.py:60} INFO - Configured default timezone UTC
[2024-06-07 18:21:26 +0500] [79] [INFO] Starting gunicorn 22.0.0
[2024-06-07 18:21:26 +0500] [79] [INFO] Listening at: http://[::]:8793 (79)
[2024-06-07 18:21:26 +0500] [79] [INFO] Using worker: sync
[2024-06-07T18:21:26.261+0500] {manager.py:393} WARNING - Because we cannot use more than 1 thread (parsing_processes = 2) wh
en using sqlite. So we set parallelism to 1.
[2024-06-07 18:21:26 +0500] [81] [INFO] Booting worker with pid: 81
[2024-06-07 18:21:26 +0500] [82] [INFO] Booting worker with pid: 82

home@DESKTOP-BRAC6VD: ~
(airflow_env) home@DESKTOP-BRAC6VD:~$ source airflow_env/bin/activate
(airflow_env) home@DESKTOP-BRAC6VD:~$ airflow webserver

Running the Gunicorn Server with:
Workers: 4 sync
Host: 0.0.0.0:8080
Timeout: 120
Logfiles: - -
Access Logformat:
=====
/home/home/airflow_env/lib/python3.10/site-packages/flask_limiter/extension.py:333 UserWarning: Using the in-memory storage f
or tracking rate limits as no storage was explicitly specified. This is not recommended for production use. See: https://flas
k-limiter.readthedocs.io#configuring-a-storage-backend for documentation about configuring the storage backend.
[2024-06-07 18:21:48 +0500] [108] [INFO] Starting gunicorn 22.0.0
[2024-06-07 18:21:48 +0500] [108] [INFO] Listening at: http://0.0.0.0:8080 (108)
[2024-06-07 18:21:48 +0500] [108] [INFO] Using worker: sync
[2024-06-07 18:21:48 +0500] [115] [INFO] Booting worker with pid: 115
[2024-06-07 18:21:48 +0500] [116] [INFO] Booting worker with pid: 116
[2024-06-07 18:21:48 +0500] [117] [INFO] Booting worker with pid: 117
[2024-06-07 18:21:48 +0500] [118] [INFO] Booting worker with pid: 118
  
```

Рисунок 2.15 – Процесс запуска системы Apache Airflow




Рисунок 2.16 – Графический интерфейс внутри Apache Airflow

Для представленного выше процесса также задается его план выполнения – в 00:00 каждого дня по московскому времени.

Telegram–бот.

В связи с тем, что конечный потребитель информации должен получать прогнозируемые значения в понятном и удобном виде, было принято решение об использовании бота в Телеграм.

Используя пакеты, способные реализовать данную задачу (Aiogram, APScheduler, Asyncio), находящиеся в открытом доступе, была написана программа на языке Python, которая ежедневно, после выполнения ETL процесса, отправляет прогнозные значения напрямую в мессенджер (2.17).

После того как пользователь запустит бота и подпишется на прогнозную рассылку, его ID будет включен в базу данных, основываясь на которую, бот понимает, кому нужно отправлять её.

```
По итогам сегодняшнего дня (2024-06-05) был составлен
следующий прогноз:
afks : 12.3 P
aflt : 27.34 P
agrodr : 664.8 P
alrs : 60.7 P
cbom : 7.33 P
chmf : 875.2 P
enpg : 416.5 P
fees : 0.09 P
fivedr : 1513.0 P
flot : 42.45 P
gazp : 157.88 P
gltrdr : 301.15 P
gmkn : 147.8 P
hydr : 0.76 P
irao : 3.41 P
lkoh : 3942.5 P
magn : 33.91 P
mgnt : 4586.5 P
msng : 1.77 P
mtlr : 104.51 P
mtss : 239.0 P
nlmk : 111.26 P
nvtk : 1020.2 P
ozondr : 1606.0 P
phor : 6398.0 P
pikk : 609.3 P
plzl : 8435.0 P
poly : 425.4 P
posi : 1397.0 P
rosl : 336.75 P
rtkm : 56.87 P
rual : 41.18 P
sber : 152.66 P
```

Рисунок 2.17 – Пример сообщения от Телеграм-бота

Также в боте предусмотрены команды, позволяющие подписаться, или же отписаться от данной рассылки (Рисунок 2.18).

```
SP /subscribe Подписаться на прогноз
SP /unsubscribe Отписаться от прогноза
```

Рисунок 2.18 – Встроенные команды бота

2.4 Вычислительные эксперименты и анализ их результатов

Рассмотрим процесс вычислительного эксперимента на примере компании «Алроса».

Таблица 1 – Обучающие данные

Date	Price	Open	High	Low	Value	Neutral	Positive	Negative
2014-02-14	36,20	36,01	36.35	35.52	$2.09 \cdot 10^6$	0,692	0,261	0,047
2014-02-17	36,00	36,20	36.48	35.80	$1.03 \cdot 10^6$	0,822	0,147	0,031
2014-02-19	36,54	35,51	35.60	35.51	$2.18 \cdot 10^6$	0,181	0,068	0,751
2014-02-26	37,25	36,82	37.25	36.82	$2.85 \cdot 10^6$	0,821	0,147	0,031
2014-03-03	35,52	36,58	37.90	34.5	$8.74 \cdot 10^6$	0,815	0,149	0,035
...	...	...	...	...	...	...	...	...

В ходе обучения модели по эпохам, как было сказано ранее, происходило отслеживание метрик MAE – Mean Squared Error (Средняя квадратичная ошибка) и MAPE – Mean Absolute Percentage Error (Средняя абсолютная процентная ошибка).

На рисунке 2.19 представлены данные показатели в зависимости от эпохи обучения.

Как видно из графика, данные параметры последовательно уменьшаются до шестой эпохи, после чего их проверочные значения начинают меняться хаотичным образом, что говорит о том, что модель начала переобучаться и слишком сильно подстраиваться под тренировочные значения, выводя неверный результат при проверке. Таким образом для этой компании сохраняется и в дальнейшем будет применяться модель, соответствующая шестой эпохе обучения.

После того как наилучшая модель была выявлена и сохранена, необходимо провести её тестирование и замер показателей, описывающих её метрик.

Графики результата предсказания цены представлены на рисунках 2.20 и 2.21 ниже. Голубой и зеленой линией отмечены цены акций, а оранжевой и красной – цены, спрогнозированные моделью.




Рисунок 2.19 – Изменение наблюдаемых метрик по эпохам обучения




Рисунок 2.20 – Результат предсказания цен акций компании «Алроса»




Рисунок 2.21 – Результаты предсказания цен акций компании «Алроса» на тестовых данных

В общем случае полученные данные имеют вид (Таблица 2):

Таблица 2 – Полученные данные в результате прогноза

Date	Price	Open	High	Low	Value	Neutral	Positive	Negative	Predict
2014-02-14	36,20	36,01	36.35	35.52	$2.09 \cdot 10^6$	0,692	0,261	0,047	36,80
2014-02-17	36,00	36,20	36.48	35.80	$1.03 \cdot 10^6$	0,822	0,147	0,031	35,18
2014-02-19	36,54	35,51	35.60	35.51	$2.18 \cdot 10^6$	0,181	0,068	0,751	36,10
2014-02-26	37,25	36,82	37.25	36.82	$2.85 \cdot 10^6$	0,821	0,147	0,031	37,74
2014-03-03	35,52	36,58	37.90	34.5	$8.74 \cdot 10^6$	0,815	0,149	0,035	39,18
...	...	...	...	...	...	...	...	...	...

2.4.1 Оценка моделей по метрикам качества

Метрика MSE.

Данная метрика рассчитывается по следующей формуле (2):

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad (2)$$

где n – количество наблюдений;

y_i – фактическое значение зависимой переменной;

$\hat{y}_i$ – предсказанное моделью значение зависимой переменной.

По результатам наблюдений, метрика MSE на обучающем наборе выдала значение 12,549, а на тестовом – 47,141. Так как данный параметр направлен на отражение влияния именно больших ошибок, то по результатам предсказания на обучающем наборе (12,549) при минимальном и максимальном значении ~40 и ~140 пунктов соответственно, данный показатель показывает себя достаточно хорошо, чего нельзя сказать про прогнозирование на тестовом наборе. Такой результат (47,141) учитывает помехи, основанные на крайней нестабильности российского рынка в целом, которые происходили в феврале 2022 года.

Метрика RMSE.

Данная метрика вычисляется по следующей формуле (3):

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (3)$$

Параметр RMSE по своей сути вычисляется как корень из среднеквадратичной ошибки, то есть зависит от него напрямую. Таким образом для

данной модели были получены следующие характеристики метрики: на обучающих данных $RMSE = 3,542$, на тестовых $RMSE = 6,866$.

Метрика MAE.

Средняя абсолютная ошибка (Mean Absolute Error) рассчитывается как среднее значение модуля разности предсказанного и фактического значений. Данный параметр, в отличие от двух предыдущих является линейной оценкой, то есть все ошибки предсказаний в среднем взвешиваются одинаково. Параметр имеет следующую формулу расчёта (4):

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4)$$

Чем меньше значение показывает MAE, тем лучше модель предсказывает фактические значения. Это означает, что модель имеет более высокую точность.

Преимущества метрики MAE включают простоту понимания и интерпретации, а также устойчивость к выбросам. Однако она не учитывает направление ошибки и может быть чувствительной к большим отклонениям.

При расчёте данного параметра на модели для компании «Алроса» были получены следующие результаты: для тренировочных данных: $MAE = 2,722$, для тестовых данных: $MAE = 4,891$.

Метрика MAPE.

Средняя абсолютная процентная ошибка (Mean Absolute Percentage Error) представляет собой среднее абсолютное процентное отклонение между фактическими значениями и предсказанными. Рассчитывается согласно формуле (5):

$$MAPE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{|y_i|} \quad (5)$$

Данная метрика даёт более наглядное представление о модели и означает на сколько процентов в среднем модель ошибается в своих прогнозах.

По результатам обучения для рассматриваемой нейросети были получены следующие значения метрик: на тренировочных данных $MAPE = 3,535\%$, на тестовых данных $MAPE = 5,062\%$. Дословно расшифровывается так: в среднем модель при предсказании ошибается на $5,062\%$.

Таким образом в ходе обучения модели были получены следующие метрики (Таблица 3):

Таблица 3 – Сводная таблица рассчитанных метрик для компании «Алроса»

	MSE	RMSE	MAE	MAPE
Тренировочное значение	12,549	3,542	2,722	3,535 %
Тестовое значение	47,141	6,866	4,891	5,062 %

2.4.2 Анализ влияния новостного фона на предсказание цены

Для того чтобы понять, как влияет тональная составляющая на котировки и прогнозные значения, была составлена матрица корреляции. Коэффициент корреляции может принимать значения от -1 до +1. Значение 0 означает отсутствие корреляции, а значение 1 или -1 означает полную корреляцию.

На основе полученных результатов можно сделать следующие выводы:

Нейтральная составляющая новостного фона практически не влияет на цену акций. Это означает, что акции не реагируют на нейтральные новости.

Позитивное влияние на цену оказывают позитивно направленные новости. Это может быть связано с тем, что позитивные новости могут вызвать рост оптимизма инвесторов и, как следствие, рост спроса на акции.

Негативное влияние на цену имеют негативные новости. Это может быть вызвано тем, что негативные новости могут вызвать снижение доверия инвесторов и, соответственно, снижение спроса на акции.




Рисунок 2.22 – Матрица корреляции параметров

Проведем эксперимент, повторяющий проделанные выше действия без учёта тональной составляющей новостей. То есть, создадим модель, в которой обучение будет происходить только на данных изменения котировок компаний.

В общем случае обучающие данные имеют вид (Таблица 4):

Таблица 4 – Обучающие данные без учёта тональной составляющей

Date	Price	Open	High	Low	Value
2014-02-14	36,20	36,01	36.35	35.52	$2.09 \cdot 10^6$
2014-02-17	36,00	36,20	36.48	35.80	$1.03 \cdot 10^6$
2014-02-19	36,54	35,51	35.60	35.51	$2.18 \cdot 10^6$
2014-02-26	37,25	36,82	37.25	36.82	$2.85 \cdot 10^6$
2014-03-03	35,52	36,58	37.90	34.5	$8.74 \cdot 10^6$
...	...	...	...	...	...

В ходе обучения также получаем график изменения метрик модели в зависимости от эпох (Рисунок 2.23):




Рисунок 2.23 – Изменение наблюдаемых метрик по эпохам обучения без тональной составляющей

Как видно из графика, данные параметры последовательно уменьшаются до пятой эпохи, после чего их проверочные значения начинают меняться хаотичным образом, что говорит о том, что модель начала переобучаться и слишком сильно подстраиваться под тренировочные значения, выводя неверный результат при проверке. Таким образом для этой компании сохраняется и в дальнейшем будет применяться модель, соответствующая пятой эпохе обучения.

После того как наилучшая модель была выявлена и сохранена, проведем операцию прогнозирования используя полученную модель. В ходе выполнения этого действия были получены следующие графики результатов предсказания, показанные на рисунках 2.24 и 2.25.




Рисунок 2.24 - Результат предсказания цен акций компании «Алроса» без учёта тональной составляющей



Рисунок 2.25 - Результат предсказания цен акций компании «Алроса» без учёта тональной составляющей на тестовых данных

Также вычислим метрики качества полученной модели (Таблица 5):

Таблица 5 - Сводная таблица рассчитанных метрик для компании «Алроса» без учёта тональной составляющей

	MSE	RMSE	MAE	MAPE
Тренировочное значение	26,222	5,120	4,253	5,426 %
Тестовое значение	93,584	9,674	7,227	7,219 %

Для того чтобы проверить влияние новостных потоков, составим сводную таблицу метрик модели с учётом тональной составляющей и без (Таблица 6).

Таблица 6 – Сводная таблица сравнения метрик качества двух моделей

	MSE	RMSE	MAE	MAPE
Тренировочное значение	12,549	3,542	2,722	3,535 %
Тренировочное значение без тональности	26,222	5,120	4,253	5,426 %
Отклонение	108,95 %	44,55%	56,24%	53,49 %
Тестовое значение	47,141	6,866	4,891	5,062 %
Тестовое значение без тональности	93,584	9,674	7,227	7,219 %
Отклонение	98,52 %	40,90 %	47,76 %	42,61 %

Таким образом, исходя из полученных данных, можно говорить о том, что использование тональной составляющей при создании и обучении нейросети положительно сказывается на её выдаваемом прогнозном значении, а также может улучшить качество моделей и повысить их эффективность.

Заключение

В ходе проделанной работы проанализирована предметная область для решения поставленной задачи

1. В рамках проекта была проведена работа по анализу предметной области, связанной с прогнозированием цен на акции компаний. Были изучены существующие методы и подходы к решению этой задачи. На основании проанализированной предметной области было определено, что выбранная тема актуальна в современном мире и требует дальнейшего развития.

2. На основе проведённого анализа был разработан алгоритм работы системы, который включает в себя сбор данных, их предобработку, проведение анализа тональности, обучение нейросетей, а также прогнозирование цен.

3. Для обучения моделей нейросетей были собраны следующие исходные данные: новости по компаниям (97 572 записей, содержащих информацию о событиях, происходящих в компаниях), а также данные по котировкам. Эти данные были использованы для обучения моделей нейросетей и прогнозирования цен на следующий день.

4. Текстовые данные, собранные из новостей, были предобработаны с помощью алгоритмов лемматизации и встроенных Python функций. Это позволило привести текстовые данные к единому виду и упростить их обработку.

5. Модели нейросетей были обучены на основе сентиментальной составляющей каждого дня и информации о котировках. Сентиментальная составляющая — это оценка эмоционального тона текста. Она может быть положительной, отрицательной или нейтральной. Информация о котировках использовалась для того, чтобы модели могли учитывать изменения цен на акции. Всего было обучено 49 моделей нейросетей. После обучения они были использованы для прогнозирования цен на акции на следующий день. Прогнозируемые цены сравнивались с реальными ценами, чтобы оценить точность моделей.

					3221.103587.000 ПЗ	Лист
						68
Изм.	Лист	№ Документа	Подпись	Дата		

6. В ходе вычислительного эксперимента было выявлено, что тональная составляющая новостей может оказывать влияние на котировки акций. Положительные новостные дни благоприятно сказываются на ценах акций, а негативные, в свою очередь, отрицательно. Это позволяет учитывать не только финансовые показатели компаний, но и их репутацию и имидж.

7. Разработанное программное обеспечение позволяет непрерывно прогнозировать цены на основе новых данных, поступающих в систему. Это позволяет оперативно реагировать на изменения цен и принимать обоснованные решения о взаимодействии с акциями.

Таким образом, в рамках проекта была успешно проанализирована предметная область и разработан алгоритм работы системы для прогнозирования цен на акции компаний. В результате было собрано и обработано 97 572 записи новостей по компаниям и котировки акций. На основе полученных данных обучено 49 моделей нейросетей.

Разработанное программное обеспечение позволяет непрерывно прогнозировать цены на основе новых данных. Это даёт возможность оперативно реагировать на изменения цен и принимать обоснованные решения о взаимодействии с акциями. Результаты проекта могут быть полезны для инвесторов, трейдеров и других участников рынка ценных бумаг.

Я подтверждаю, что настоящая работа написана мною лично, не нарушает интеллектуальные права третьих лиц и не содержит сведения, составляющие государственную тайну.

 / Семенов К.С.

					3221.103587.000 ПЗ	Лист
						69
Изм.	Лист	№ Документа	Подпись	Дата		

Список литературы

- 1 М.Л. Кричевский. Финансовые риски. – М.: КноРус, 2013. – 248 с.
- 2 Li, Bu & Wu (2017) Li J, Bu H, Wu J. Sentiment-aware stock market prediction: a deep learning method. 2017 international conference on service systems and service management; Piscataway. 2017. pp. 1–6.
- 3 Shah, Isah & Zulkernine (2019) Shah D, Isah H, Zulkernine F. Stock market analysis: a review and taxonomy of prediction techniques. International Journal of Financial Studies. 2019;7(2):1–22. doi: 10.3390/ijfs7020026.
- 4 Shah, Isah & Zulkernine (2019) Shah D, Isah H, Zulkernine F. Stock market analysis: a review and taxonomy of prediction techniques. International Journal of Financial Studies. 2019;7(2):1–22. doi: 10.3390/ijfs7020026.
- 5 Bustos & Pomares-Quimbaya (2020) Bustos O, Pomares-Quimbaya A. Stock market movement forecast: a systematic review. Expert Systems with Applications. 2020;156:1–15.
- 6 Nelson, Pereira & de Oliveira (2017) Nelson DM, Pereira AC, De Oliveira RA. Stock market's price movement prediction with LSTM neural networks. 2017 International joint conference on neural networks (IJCNN); Piscataway. 2017. pp. 1419–1426.
- 7 Xia, Liu & Chen (2013) Xia Y, Liu Y, Chen Z. Support Vector Regression for prediction of stock trend. 2013 6th international conference on information management, innovation management and industrial engineering; Piscataway. 2013. pp. 123–126.
- 8 Liu et al. (2017) Liu Y, Qin Z, Li P, Wan T. Stock volatility prediction using recurrent neural networks with sentiment analysis. In: Benferhat S, Tabia K, Ali M, editors. Advances in Artificial Intelligence: From Theory to Practice. IEA/AIE 2017. Lecture Notes in Computer Science, vol 10350. Cham: Springer; 2017.
- 9 Gao, Chai & Liu (2017) Gao T, Chai Y, Liu Y. Applying long short term memory neural networks for predicting stock closing price. 2017 8th IEEE international

conference on software engineering and service science (ICSESS); Piscataway. 2017. pp. 575–578.

10 Lee & Soo (2017) Lee C-Y, Soo V-W. Predict stock price with financial news based on recurrent convolutional neural networks. 2017 conference on technologies and applications of artificial intelligence (TAAI); Piscataway. 2017. pp. 160–165.

11 Khare et al. (2017) Khare K, Darekar O, Gupta P, Attar V. Short term stock price prediction using deep learning. 2017 2nd IEEE international conference on recent trends in electronics, information & communication technology (RTEICT); Piscataway. 2017. pp. 482–486.

12 Lu (2018) Lu Y-J. Hsinchu City: National Chiao Tung University; 2018. Stock prediction using deep learning and sentiment analysis; pp. 1–44.

13 Riabikh A, Surzhko D, Konovalikhin M, Koltcov S. 2022. STTM: an efficient approach to estimating news impact on stock movement direction. PeerJ Computer Science 8:e1156 <https://doi.org/10.7717/peerj-cs.1156>

14 А.Б. Барский. Логические нейронные сети. – М.: Интернет-университет информационных технологий, Бином. Лаборатория знаний, 2007. – 352 с.

15 Е.В. Боровская, Н.А. Давыдова. Основы искусственного интеллекта. – М.: Бином. Лаборатория знаний, 2010. – 128 с.

16 Г.Э. Яхьяева. Нечеткие множества и нейронные сети. – М.: Интернет-университет информационных технологий, Бином. Лаборатория знаний, 2011. – 320 с.

17 А.И. Галушкин. Нейронные сети. Основы теории. – М.: Горячая Линия - Телеком, 2012. – 496 с.

 / Семенов К.С.

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«УФИМСКИЙ УНИВЕРСИТЕТ НАУКИ И ТЕХНОЛОГИЙ»
Факультет информатики и робототехники
Кафедра вычислительной математики и кибернетики

ОТЗЫВ
на выпускную квалификационную работу

студента Семенова Кирилла Станиславовича

(фамилия, имя, отчество (при наличии) полностью)

Уровень профессионального образования: высшее образование – магистратура

(бакалавриат, специалитет, магистратура)

Направление подготовки (специальность): 09.04.01 Информатика и вычислительная техника

(код и наименование)

Направленность (профиль) образовательной программы: Компьютерный анализ и интерпретация данных

Наименование темы выпускной квалификационной работы: Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций

Руководитель выпускной квалификационной работы: доцент, к.ф.-м.н., доцент,

Прокудина Елена Ивановна

(ученое звание, ученая степень, должность, фамилия, имя, отчество полностью)

Консультант выпускной квалификационной работы (при наличии): _____

доцент, к.ф.-м.н., доцент, Прокудина Елена Ивановна

(ученое звание, ученая степень, должность, фамилия, имя, отчество полностью)

Выпускная квалификационная работа (далее – ВКР) (нужное отметить «V»):

V	выполнена на тему, утвержденную приказом Университета (директором филиала)
V	содержание ВКР соответствует теме ВКР, утвержденной приказом Университета (директора филиала)
V	выполнена с соблюдением сроков сдачи завершенной ВКР
V	Выполнена с соблюдением требований к ВКР, установленных Положением о ВКР, а также программой ГИА по соответствующему направлению подготовки (специальности) и методическим рекомендациям по выполнению ВКР.

Выпускная квалификационная работа Семенова К.С. посвящена актуальной теме – разработке программного обеспечения, позволяющего непрерывно, на основе новых данных, прогнозировать курсы акций, при этом учитывая влияние новостной информации, появляющейся в средствах массовой информации.

В процессе работы Семенов К.С. продемонстрировал умение работать с обширной литературой по теме исследования, с крупными наборами данных, применять методы машинного обучения, эффективно использовать инструменты анализа данных.

Предлагаемый в работе подход, полученные результаты имеют практический интерес для потенциальных инвесторов.

Планируется публикация по материалам выпускной квалификационной работы.

Семенов К.С. проявил себя как самостоятельный и инициативный студент, продемонстрировал умение решать задачи, требующие глубоких профессиональных знаний, ответственность и организованность.

Поставленные задачи решены, пояснительная записка к выпускной работе написана корректно, нормы и требования, предъявляемые к ее оформлению, выдержаны.

Выпускная квалификационная работа Семенова Кирилла Станиславовича соответствует требованиям образовательной программы высшего образования к профессиональной подготовке по данному направлению.


Приложение: Отчет (справка) о проверке на объем заимствования на 1 л. в 1 экз.

Руководитель
выпускной квалификационной работы

 / Прокудина Е.И.
(подпись) (Фамилия, И.О.)

«20» июня 2024 г.

С отзывом на выпускную квалификационную
работу ознакомлен:
Обучающийся

 / Семенов К.С.
(подпись) (Фамилия, И.О.)

«20» июня 2024 г.

РЕЦЕНЗИЯ

на выпускную квалификационную работу

студента Семенова Кирилла Станиславовича

Уровень профессионального образования: высшее образование – магистратура

Направление подготовки (специальность): 09.04.01 Информатика и вычислительная техника

Направленность (профиль) образовательной программы: Компьютерный анализ и интерпретация данных

Наименование темы выпускной квалификационной работы: Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций

С развитием технологий и доступностью информации, СМИ стали мощным инструментом влияния на общественное мнение и финансовые рынки. Анализ влияния информации в СМИ на курсы акций является актуальной задачей для инвесторов, аналитиков и регуляторов рынка. Рассматриваемая выпускная квалификационная работа посвящена разработке программного обеспечения задачи анализа влияния информации в СМИ на курсы акций.

В выпускной квалификационной работе проведен анализ и исследование предметной области, в ходе которого была выявлена необходимость разработки предлагаемого программного решения; выполнен сравнительный анализ моделей, методов и программных продуктов для решения подобных задач, рассмотрены основные подходы к реализации предлагаемого продукта.

Семеновым К.С. проанализированы и реализованы алгоритмы для решения следующих задач: сбор данных новостей и курсов акций, предобработка новостей, анализ тональности новостных потоков, создание моделей нейронных сетей для прогнозирования цен акций. Для обучения моделей нейросетей собран и обработан обширный массив данных, содержащий 97 572 записи, построены нейросети для 49 акций.

Разработанное Семеновым К.С. программное обеспечение, позволяет непрерывно прогнозировать цены акций на основе новых данных, для этого реализован ETL-процесс. Создан Telegram-бот для автоматического оповещения пользователей.

ВКР полностью соответствует выданному заданию и имеет практическую ценность для участников рынка ценных бумаг.

ВКР выполнена грамотно, термины используются правильно, выводы четко сформулированы и логичны.

Заключение: Рецензируемая ВКР полностью отвечает требованиям, предъявляемым к выпускным квалификационным работам, заслуживает оценки отлично, а ее автор – Семенов К.С. достоин присвоения квалификации магистр по направлению 09.04.01 «Информационная и вычислительная техника» (профиль «Компьютерный анализ и интерпретация данных»).

Рецензент
доцент, к.т.н., зав. кафедрой информационных технологий БГПУ им. Акмуллы

С рецензией на выпускную квалификационную работу ознакомлен:
Обучающийся



/Васильева Л. И.

/Семенов К.С.

“14” июня 2024 г.

Подпись Л.И. Васильева
Заведующий; Начальник отдела документационного обеспечения
ФГБОУ ВО «БГПУ им. М.А. Акмуллы» Л.И. Васильева



АНТИПЛАГИАТ
ОБНАРУЖЕНИЕ ЗАИМСТВОВАНИЙ

СПРАВКА

о результатах проверки текстового документа
на наличие заимствований

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ
БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
"УФИМСКИЙ УНИВЕРСИТЕТ НАУКИ И
ТЕХНОЛОГИЙ"

ПРОВЕРКА ВЫПОЛНЕНА В СИСТЕМЕ АНТИПЛАГИАТ.ВУЗ

Автор работы: Семенов К.С.
Самоцитирование
рассчитано для: Семенов К.С.
Название работы: Semenov_K_S
Тип работы: Выпускная квалификационная работа
Подразделение: Кафедра вычислительной математики и кибернетики

РЕЗУЛЬТАТЫ

- ВНИМАНИЕ, ДОКУМЕНТ ПОДОЗРИТЕЛЬНЫЙ: ОБНАРУЖЕНЫ ПОПЫТКИ МАСКИРОВКИ ЗАИМСТВОВАНИЙ. РЕКОМЕНДУЕТСЯ ПРОВЕРИТЬ ПОЛНЫЙ ОТЧЕТ
- ОТЧЕТ О ПРОВЕРКЕ КОРРЕКТИРОВАЛСЯ: НИЖЕ ПРЕДСТАВЛЕНЫ РЕЗУЛЬТАТЫ ПРОВЕРКИ ДО КОРРЕКТИРОВКИ

СОВПАДЕНИЯ 24.83%
ОРИГИНАЛЬНОСТЬ 75.17%
ЦИТИРОВАНИЯ 0%
САМОЦИТИРОВАНИЯ 0%

СОВПАДЕНИЯ 24.83%
ОРИГИНАЛЬНОСТЬ 75.17%
ЦИТИРОВАНИЯ 0%
САМОЦИТИРОВАНИЯ 0%

ДАТА ПОСЛЕДНЕЙ ПРОВЕРКИ: 08.06.2024

ДАТА И ВРЕМЯ КОРРЕКТИРОВКИ: 08.06.2024 11:21

Структура
документа:

Проверенные разделы: титульный лист с.1, основная часть с.1-40

Модули поиска:

Шаблонные фразы; IEEE; Издательство Wiley; Цитирование; Библиография; Перефразированные заимствования по коллекции Интернет в английском сегменте; Интернет Плюс*; Перефразирования по коллекции издательства Wiley; Переводные заимствования*; Диссертации НББ; Перефразирования по Интернету (EN); Коллекция НБУ; Перефразирования по коллекции IEEE; ИПС Адилет; Публикации eLIBRARY; СМИ России и СНГ; Медицина; Переводные заимствования по Интернету (EnRu); Переводные заимствования по коллекции Интернет в русском сегменте; Кольцо вузов; Переводные заимствования издательства Wiley; СПС ГАРАНТ; аналитика; Переводные заимствования по коллекции Гарант: аналитика; Патенты СССР, РФ, СНГ; Сводная коллекция ЭБС; Публикации РГБ; Публикации eLIBRARY (переводы и

Работу проверил: Воробьева Гульнара Равиловна

ФИО проверяющего

Дата подписи:

08.06.24

Подпись проверяющего



Чтобы убедиться
в подлинности справки, используйте QR-код,
который содержит ссылку на отчет.

Ответ на вопрос, является ли обнаруженное заимствование
корректным, система оставляет на усмотрение проверяющего.
Предоставленная информация не подлежит использованию
в коммерческих целях.

Институт Информатики, математики и робототехники
Кафедра Вычислительной математики и кибернетики

Автореферат

к выпускной квалификационной работе
на тему: «РАЗРАБОТКА ПРОГРАММНОГО ОБЕСПЕЧЕНИЯ ЗАДАЧИ
АНАЛИЗА ВЛИЯНИЯ ИНФОРМАЦИИ В СМИ НА КУРСЫ АКЦИЙ.»

Зав. кафедрой ВМиК

Шахматова Г.Р. (подпись)

« 19 » 06 2024 г.

Обучающийся:

Семенов К.С. (подпись)

Руководитель выпускной квалификационной работы

Прокудина Е.И. (подпись)

Уфа – 2024

1. ОБЩАЯ ХАРАКТЕРИСТИКА ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

Тема выпускной квалификационной работы (ВКР): «Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций».

Актуальность темы. С развитием технологий и доступностью информации, СМИ стали мощным инструментом влияния на общественное мнение и финансовые рынки. Анализ влияния информации в СМИ на курсы акций является актуальной задачей для инвесторов, аналитиков и регуляторов рынка. Выпускная квалификационная работа посвящена разработке программного обеспечения задачи анализа влияния информации в СМИ на курсы акций.

Цель ВКР заключается в разработке ПО, способного проводить анализ воздействия информации, распространяемой в средствах массовой информации, на цены акций компаний на финансовых рынках и прогнозировать их.

Задачи ВКР:

- 1) Провести аналитический обзор предметной области;
- 2) Составить общую методику работы создаваемой системы прогнозирования;
- 3) Провести сбор данных, получить новостные данные, а также котировки;
- 4) Провести предобработку текстовых данных новостей, привести в вид, понятный для модели нейронной сети;
- 5) Создать и обучить модели нейронных сетей, способных предсказывать будущую цену акции, на основе прошлых данных котировок и новостного потока;
- 6) Провести вычислительный эксперимент на основе полученных моделей нейросетей.
- 7) Реализовать программное обеспечение для выдачи прогноза, основанное на полученных моделях нейронных сетей.

Структура и объем работы: ВКР состоит из введения, аналитической части, проектной части, заключения и списка литературы. ВКР изложена на 71 странице, иллюстрирована 36 рисунками, 6 таблицами. Список литературы включает 17 работ.

2. ХАРАКТЕРИСТИКА СОДЕРЖАНИЯ ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

В первой главе были исследованы и проанализированы предметная область, модели, методы, программные продукты для решения задач анализа влияния информации в СМИ на курсы акций, а также составлена формальная постановка задачи на разработку.

В ходе анализа предметной области были определены ключевые составляющие для разработки продукта. Также был рассмотрен опыт авторов предыдущих работ, посвященных развитию данной темы. Анализ их работ позволил понять важность и актуальность темы, а также основные преимущества и недостатки существующих решений в данной области.

В результате анализа моделей, методов и программных продуктов были рассмотрены основные подходы к решению данной задачи, такие как использование методов машинного обучения, различных видов нейросетей, методы обработки текста, а также нейросетевые технологии для определения тональности текста. Также были выявлены существующие решения в виде готовых программных продуктов.

Затем была определена основная цель выполняемой работы в виде формальной постановки задачи и дальнейшей её декомпозиции, составляющей структуру решения.

Вторая глава посвящена разработке проектной части решения. На основе индекса Мосбиржи составляется набор из 49 рассматриваемых компаний. Составляется алгоритм работы системы, способной создавать прогноз цен акций для выбранных компаний, в который входят сбор данных новостей и курсов акций, предобработка новостей, анализ тональности новостных потоков, создание моделей нейронных сетей для прогнозирования цен акций.

Также приводятся концептуальная и логическая модели базы данных, используемых в работе. Системой управления базой данных была выбрана PostgreSQL 16 за счёт своей простоты, гибкости и удобства в использовании.

Затем в работе описывается сбор данных новостей и котировок с использованием библиотеки Selenium с интернет-ресурсов finam.ru – для новостей и investing.com – для котировок компаний. В результате сбора данных было собрано 97 572 записи новостей, а также ежедневные котировки для каждой из выбранных компаний.

В дальнейшем происходит обработка текстовых данных с использованием встроенных функций Python, а также программного продукта компании Яндекс – Rumystem 3 для лемматизации текста. Затем проводится анализ тональности полученных данных с использованием нейросети, основанной на архитектуре трансформеров – RuBERT, в результате которого каждый день представляется в виде вектора, состоящего из нейтральной, позитивной и негативной составляющих:

$$\text{Tonality} = [\text{Neutral}, \text{Positive}, \text{Negative}],$$

где Neutral – нейтральная составляющая текста;

Positive – позитивная составляющая текста;

Negative – негативная составляющая текста.

После того как тональные составляющие дней были определены, они объединяются с данными котировок акций и представляются в виде обучающих данных для создаваемых нейросетей.

Основой архитектуры моделей, способных прогнозировать цены акций, является ячейка LSTM, преимущество которых заключается в запоминании входящих в неё данных, в результате которого контекст поступаемых новостей сохраняется. Таким образом, с помощью библиотек Keras, Tensorflow, а также Scikit-Learn были созданы и успешно обучены 49 моделей нейросетей на каждую акцию.

Результат работы данных нейросетей оценивался по метрикам качества: среднеквадратичная ошибка и отклонение (MSE, RMSE), средняя абсолютная ошибка (MAE), а также средняя процентная абсолютная ошибка (MAPE). Полученные параметры приведены в таблице ниже:

Таблица 1 - Сводная таблица рассчитанных метрик для компании «Алроса»

	MSE	RMSE	MAE	MAPE
Тренировочное значение	12,549	3,542	2,722	3,535 %
Тестовое значение	47,141	6,866	4,891	5,062 %

Также в ходе вычислительного эксперимента была построена нейросеть, обученная на данных только котировок компаний, результаты работы которой оказались хуже в среднем на 55%, что доказывает положительный эффект использования данных новостей при создании моделей прогноза.

Для создания программного обеспечения был разработан ETL-процесс, способный ежедневно собирать котировки акций, а также новости компаний, проводить их обработку и, с использованием разработанных нейросетей проводить прогнозирование цен. Для реализации данного процесса был построен ориентированный ациклический граф задач (DAG) с использованием библиотеки Apache Airflow, развернутой на Linux-подобной системе – Ubuntu 22.04.


Также для того, чтобы пользователи могли в удобной форме получать автоматические оповещения о прогнозных значениях, разработан Telegram-бот с использованием библиотек Aiogram 3, а также встроенной в Python библиотекой для асинхронного выполнения задач – Asyncio.

Таким образом было разработано программное обеспечение задачи анализа влияния информации в СМИ на курсы акций.



УФИМСКИЙ
УНИВЕРСИТЕТ
НАУКИ И ТЕХНОЛОГИЙ

Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций




Выполнил: ст. гр. КАИД-212М Семенов К.С.

Научный руководитель: доцент, к.ф.-м.н. Прокудина Е.И.

» Актуальность

Доля частных инвесторов в объеме торгов акциями




* Источник БКС, Московская биржа

БКС ЭКСПРЕСС

Информирование посредством Telegram-бота предоставляет удобство и простоту реализации ежедневного прогнозирования в виде оповещений.

Популярность СМИ*



Основные виды СМИ




»» Цель и задачи

Цель работы: разработать ПО, позволяющее проводить анализ воздействия информации, распространяемой в СМИ, на цены акций компаний и прогнозировать их.


Задачи работы:

1. Провести аналитический обзор предметной области;
2. Составить алгоритм работы системы, способной составлять прогноз котировок акций;
3. Собрать исходные данные;
4. Провести предобработку полученных данных;
5. Разработать модели нейросетей;
6. Провести вычислительный эксперимент;
7. Разработать программное обеспечение для выдачи прогноза цен акций.


»» Формальная постановка задачи



» Структура решения



» Структура решения



»» Содержательная постановка задачи


Дано:

Множество компаний-эмитентов.

Поток финансовых новостей с сайта finam.ru и временные ряды финансовых показателей с сайта investing.com за период с 2014 по 2024 год.

Найти:

Прогнозные значения цен акций.



Общая методика работы системы прогнозирования курсов акций



» 1. Сбор данных


С помощью парсеров собираются:

1. Новости 49 компаний-эмитентов с сайта finam.ru с 2014 по 2024 год, разделенные на отдельные таблицы. Количество новостей по каждой компании варьируется от 500 до 11 000.
2. Временные ряды финансовых показателей рассматриваемых компаний с сайта investing.com с 2014 по 2024 год.

Компании, входящие в датасет:

Аэрофлот, АФК, Русагро, Акрон, Алроса, МКБ, Северсталь, ЭН+, Россети, Х5, Совкомфлот, Газпром, Глобалтранс, Норникель, Русгидро, Интер РАО, Лукойл, ММК, Магнит, Мосэнерго, Мечел, МТС, НЛМК, Новатэк, Озон, Фосагро, ПИК, Полюс Золото, Полиметал, Позитив, Роснефть, Ростелеком, Русал, Сбербанк, Селигдар, Сегежа, Самолет, Сургутнефтегаз, Татнефть, Тинькофф, Транснефть, Юнипро, Вконтакте, ВТБ, Яндекс, Qiwi, ТМК, Акрон, Мать и Дитя, Ютэйр.

Общее количество новостей составило 97 572.





» 1. Сбор данных

Новости компаний — Финам

finam.ru/publications/section/companies/date/2022-01-14/

Браузером Chrome управляет автоматизированное тестовое ПО.

Финам

Открыть счет Демосчет

Новости компаний

Даты 14.01.2022

14.01.22 • Finam.ru
События предстоящих дней: пройдет ВОСА "Группы ПИК"
15 января ТГК-14 закроет реестр акционеров для участия во внеочередном общем собрании

14.01.22 • РИА Новости
Apple зарегистрировала личный кабинет на сайте Роскомнадзора
Согласно информации на сайте, Apple пока не разместила на своих информационных ресурсах электронную форму, а также не создала филиала, не открыла представительства или не учредила российское юридическое лицо

14.01.22 • Гайнутдинова Лиана, Finam.ru
Фиаско РФ в переговорах по европейской безопасности обрушило рубль и российский рынок
Старый Новый год на отечественной бирже в этом году был омрачен массированным выходом нерезидентов из российских бумаг под давлением усилившихся геополитических рисков

14.01.22 • Finam.ru
Сенатор США подготовил новый проект санкций против России и лично Путина
Предполагается, что в случае принятия законопроекта, США смогут ввести санкции против России и президента в ответ на вторжение на Украину

14.01.22 • РИА Новости
Добыча нефти в России в январе составит 10,1 млн баррелей в сутки - Новак
Штамм коронавируса "омикрон" меньше предыдущих штаммов влияет на спрос на нефть в мире, что обуславливает решения альянса ОПЕК+ по объемам добычи

9

Работа парсера новостей



Котировки Aeroflot (AFLT) за

ru.investing.com/equities/aeroflot-historical-data

Браузером Chrome управляет автоматизированное тестовое ПО.

Investing.com

Открыть приложение

Акции Фильтр акций Россия Премаркет США Мировые АДР Россия - АДР Америка Европа Бл. В

Новинка! Приобретите ProPicks и узнайте стратегию, опередившую S&P 500 более чем на 1,183% Получить СКИДКУ 40%

ОАО Аэрофлот (AFLT)

Москва Цена в RUB Предупреждение

★ Добавить в портфель

49,36 +0,93 (+1,92%) ▲

Закр. 05/04

Обзор График Новости и аналитика Отчеты Теханализ Форум

Обзор Профиль Прошлые данные Компонент индексов

Прошлые данные - AFLT

Временной период

Daily 01.01.2022 - 01.01.2024

Дата	Цена	Откр.	Макс.	Мин.	Объем	Изм. %
29.12.2023	35,05	35,10	35,40	34,70	7,78M	...
28.12.2023	34,87	35,11	35,22	34,71	7,92M	-0.68%

Работа парсера котировок



» 2. Предобработка данных

Алгоритм предобработки:

1. Приведение к нижнему регистру;
2. Очистка текста от пунктуации, цифр и англоязычных слов и букв;
3. Выделение леммы из каждого слова;
4. Удаление стоп-слов;
5. Удаление редко и часто встречающихся слов.

Пример

«Чистая прибыль АФК "Система" по US GAAP в 2013 году выросла на 11,1% - до \$2 млрд».

1. «чистая прибыль афк "система" по us gaap в 2013 году выросла на 11,1% - до \$2 млрд»
2. «чистая прибыль афк система по в году выросла на до млрд»
3. «чистый прибыль афк система по в год вырастать на до млрд»
4. «чистый прибыль афк система вырастать»
5. «чистый прибыль вырастать»



»» 3. Анализ тональности новостей

При проведении анализа тональности используется нейросеть **RuBERT-base-cased-sentiment**, основанная на архитектуре трансформеров.

На выходе нейросети формируется вектор тональности:

$$Tonality = [Neutral, Positive, Negative],$$

где *Neutral* – нейтральная составляющая текста;

Positive – позитивная составляющая текста;

Negative – негативная составляющая текста.

Пример

Входные данные: «выручка группа включая прочий деятельность увеличиваться примерно прошлое материал алмазодобыча карат реализация запас нейтральный динамика алмазный квартал придерживаться прогноз число ювелирный качество средний технический».

Выходные данные:

Positive: 0.925;

Neutral: 0.06;

Negative: 0.014.



» 4. Создание нейронных сетей

□ Подготовка данных

Входные данные:

$$\text{Input} = \left[\begin{array}{c|ccc} a_{1,1} & \dots & a_{1,k} & b_{1,1}, b_{1,2}, b_{1,3} \\ \vdots & & \vdots & \vdots \\ a_{m,1} & \dots & a_{m,k} & b_{m,1}, b_{m,2}, b_{m,3} \end{array} \right],$$

где $a_{i,j} (i = \overline{1, m}, j = \overline{1, k})$ – значения временных рядов показателей акции;

$b_{i,l} (i = \overline{1, m}, l = \overline{1, 3})$ – значения координат векторов тональности;

m – шаг обратного просмотра;

k – количество параметров обучающего набора.

Выходные данные:


$$\text{Output} = \hat{y},$$

где $\hat{y}$ – прогнозное значение цены акции.

12



Keras



В модели присутствуют
слои:

- **LSTM** – основной слой обработки данных
- **Dropout** – слой для предотвращения переобучения
- **Dense** – слой для задания параметров регуляризации
- **Activation** – слой для вычисления функции активации в интервале от 0 до 1


» 4. Создание нейронных сетей

□ Обучение нейросетей

По результатам обучения моделей строится график метрик **MSE** и **MAE** в зависимости от эпох обучения.

В качестве примера рассмотрим компанию Алроса, для которой были получены следующие метрики:

	MSE	RMSE	MAE	MAPE
Тренировочное значение	12,549	3,542	2,722	3,535 %
Тестовое значение	47,141	6,866	4,891	5,062 %




Изменение метрик модели для компании Алроса



»» 4. Создание нейронных сетей

□ Анализ работы нейросетей





»» 4. Создание нейронных сетей

□ Анализ работы нейросетей




График фактических и предсказанных цен для компании Алроса на тестовых значениях



»» 4. Создание нейронных сетей

□ Анализ работы нейросетей



Матрица корреляции параметров



» 4. Создание нейронных сетей

□ Анализ работы нейросетей

	MSE	RMSE	MAE	MAPE
Тренировочное значение	12,549	3,542	2,722	3,535 %
Тренировочное значение без тональности	26,222	5,120	4,253	5,426 %
Отклонение	108,95 %	44,55%	56,24%	53,49 %
Тестовое значение	47,141	6,866	4,891	5,062 %
Тестовое значение без тональности	93,584	9,674	7,227	7,219 %
Отклонение	98,52 %	40,90 %	47,76 %	42,61 %


Таким образом, использование тональной составляющей при создании и обучении нейросети положительно сказывается на выдаваемом прогнозном значении.



»» 5. Прогнозирование цен акций

❑ Разработка процесса ETL

Для автоматического ежедневного прогнозирования цен акций был создан ETL-процесс для сбора и обработки данных. Внутри ОС Ubuntu с Apache Airflow данный процесс представлен в виде ориентированного ациклического графа (DAG).



Представление DAG внутри Apache Airflow



» 5. Прогнозирование цен акций


❑ Разработка Телеграм-бота

После настройки процесса ETL необходимо оповещать пользователей о полученной информации.

Для этих целей используется Telegram бот, выполняющий ежедневные запросы к сформированной базе данных, и отправляющий полученные данные в чат.

```
По итогам сегодняшнего дня (2024-06-05) был составлен
следующий прогноз:
afks : 12.3 ₺
aflt : 27.34 ₺
agrodr : 664.8 ₺
alrs : 60.7 ₺
cbom : 7.33 ₺
chmf : 875.2 ₺
enpg : 416.5 ₺
fees : 0.09 ₺
fivedr : 1513.0 ₺
flot : 42.45 ₺
gazp : 157.88 ₺
```

Пример сообщения от бота




QR-код для подключения бота





»» Диаграмма компонентов





»» Выводы

1. На основе анализа предметной области был сделан вывод, что выбранная тема ВКР актуальна и требует дальнейшего развития.
2. Разработан алгоритм работы системы прогнозирования курсов акций.
3. Собраны исходные данные: новости по 49 компаниям (97 572 записи), а также показатели акций этих компаний за 2014 – 2024 года.
4. С помощью алгоритма лемматизации, а также встроенных Python функций весь объем текстовых данных предобработан.
5. На основе значений тональной составляющей новостей, а также значений показателей акций компаний-эмитентов построены и обучены 49 моделей нейросетей.
6. В ходе вычислительного эксперимента выявлено влияние и целесообразность учёта тональной составляющей при нахождении прогнозных цен акций.
7. Разработано программное обеспечение, способное ежедневно прогнозировать цены акций.



УФИМСКИЙ
УНИВЕРСИТЕТ
НАУКИ И ТЕХНОЛОГИЙ

**Спасибо за
внимание!**



Заведующему кафедрой
Вычислительной математики и кибернетики
 (наименование кафедры)
Института информатики,
математики и робототехники
 (наименование факультета, института, школы)
 от студента (-ки) 2 курса
очной формы обучения
 (очной, очно-заочной, заочной)
 условия обучения за счет средств бюджета РФ
 (за счет средств бюджета РФ, по договору об образовании)
09.04.01 – Информатика и вычислительная
техника
 (наименование направления подготовки (специальности))
Семенова Кирилла Станиславовича
 (фамилия, имя, отчество полностью)
 Номер сотового телефона: +7-987-601-99-80
 Адрес электронной почты: ksemchh@vk.com

ЗАЯВЛЕНИЕ

Прошу утвердить тему выпускной квалификационной работы магистра
 (бакалавра, специалиста, магистра)
«Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы
акций.»
 (наименование темы)

и закрепить в качестве руководителя доцента, канд. физ. – мат. наук,
Прокудину Елену Ивановну
 (должность, ученое звание, ученая степень, фамилия, имя, отчество полностью)

Прошу разрешить выполнить выпускную квалификационную работу совместно
 со следующим(и) студентом(ами):

№	Фамилия, имя, отчество полностью	Направление подготовки (специальность)	Уровень образования	Наименование факультета (института, школы)
1	-----			
2	-----			

« 18 » января 20 24 г.

 / Семенов К.С.
 (подпись) (Фамилия И.О.)

Утвердить тему выпускной квалификационной работы.


Назначить руководителем выпускной квалификационной работы Прокудину Е.И.
 (фамилия и инициалы)

Адрес электронной почты руководителя: preliv@gmail.com

Назначить консультантом выпускной квалификационной работы доцента, канд. физ. – мат.
наук Прокудину Е. И.
 (должность, ученое звание, ученая степень (при наличии), фамилия и инициалы)

Тема выпускной квалификационной работы согласована / не согласована (нужное подчеркнуть)
 и относится к проектному / исследовательскому типу (нужное подчеркнуть).

Заведующий кафедрой

 / Шахматова Г.Р.
 (подпись) (Фамилия И.О.)

« 19 » января 20 24 г.

Федеральное государственное бюджетное образовательное учреждение
высшего образования «Уфимский университет науки и технологий»

АКТ
предварительного просмотра выпускной квалификационной работы обучающегося

Семенов Кирилл Станиславович
(фамилия, имя, отчество)

Комиссия в составе: Сметанина О.Н., д.т.н., проф., Верхотурова Г.Н., к.т.н., доц.
Нургаянова О.С., к.т.н., доц.

Рассмотрев материалы выпускной квалификации одной работы, постановила:

1. Считать, что предъявленная выпускная квалификационная работа на тему:
«Разработка программного обеспечения задачи анализа влияния информации в СМИ на
курсы акций»

соответствует заданию и выполнена в требуемом объеме.
(соответствует / не соответствует) (выполнена / не выполнена)

2. Особые замечания

3. Направить на рецензию
(фамилия, имя, отчество рецензента и наименование предприятия/организации)

Срок предъявления на рецензию

Подписи членов комиссии

Сметанина О.Н. (подпись)

Верхотурова Г.Н. (подпись)

Нургаянова О.С. (подпись)

С актом ознакомлен

Подпись обучающегося

« 11 » июня 2024г.