


Разработка программного обеспечения задачи анализа влияния информации в СМИ на курсы акций



УФИМСКИЙ
УНИВЕРСИТЕТ
НАУКИ И ТЕХНОЛОГИЙ




Выполнил: ст. гр. КАИД-212М Семенов К.С.

Научный руководитель: доцент, к.ф.-м.н. Прокудина Е.И.

» Актуальность

Доля частных инвесторов в объеме торгов акциями




* Источник БКС, Московская биржа

БКС ЭКСПРЕСС

Информирование посредством Telegram-бота предоставляет удобство и простоту реализации ежедневного прогнозирования в виде оповещений.

Популярность СМИ*



Основные виды СМИ




»» Цель и задачи

Цель работы: разработать ПО, позволяющее проводить анализ воздействия информации, распространяемой в СМИ, на цены акций компаний и прогнозировать их.


Задачи работы:

1. Провести аналитический обзор предметной области;
2. Составить алгоритм работы системы, способной составлять прогноз котировок акций;
3. Собрать исходные данные;
4. Провести предобработку полученных данных;
5. Разработать модели нейросетей;
6. Провести вычислительный эксперимент;
7. Разработать программное обеспечение для выдачи прогноза цен акций.


»» Формальная постановка задачи



» Структура решения



» Структура решения



Структура решения блока «Создание нейронных сетей»

»» Содержательная постановка задачи


Дано:

Множество компаний-эмитентов.

Поток финансовых новостей с сайта finam.ru и временные ряды финансовых показателей с сайта investing.com за период с 2014 по 2024 год.

Найти:

Прогнозные значения цен акций.



Общая методика работы системы прогнозирования курсов акций



» 1. Сбор данных

С помощью парсеров собираются:

1. Новости 49 компаний-эмитентов с сайта finam.ru с 2014 по 2024 год, разделенные на отдельные таблицы. Количество новостей по каждой компании варьируется от 500 до 11 000.
2. Временные ряды финансовых показателей рассматриваемых компаний с сайта investing.com с 2014 по 2024 год.

Компании, входящие в датасет:

Аэрофлот, АФК, Русагро, Акрон, Алроса, МКБ, Северсталь, ЭН+, Россети, Х5, Совкомфлот, Газпром, Глобалтранс, Норникель, Русгидро, Интер РАО, Лукойл, ММК, Магнит, Мосэнерго, Мечел, МТС, НЛМК, Новатэк, Озон, Фосагро, ПИК, Полюс Золото, Полиметал, Позитив, Роснефть, Ростелеком, Русал, Сбербанк, Селигдар, Сегежа, Самолет, Сургутнефтегаз, Татнефть, Тинькофф, Транснефть, Юнипро, Вконтакте, ВТБ, Яндекс, Qiwi, ТМК, Акрон, Мать и Дитя, Ютэйр.

Общее количество новостей составило 97 572.





» 1. Сбор данных

Новости компаний — Финам

finam.ru/publications/section/companies/date/2022-01-14/

Браузером Chrome управляет автоматизированное тестовое ПО.

Финам

Открыть счет Демосчет

Новости компаний

Даты 14.01.2022

14.01.22 • Finam.ru
События предстоящих дней: пройдет ВОСА "Группы ПИК"
15 января ТГК-14 закроет реестр акционеров для участия во внеочередном общем собрании

14.01.22 • РИА Новости
Apple зарегистрировала личный кабинет на сайте Роскомнадзора
Согласно информации на сайте, Apple пока не разместила на своих информационных ресурсах электронную форму, а также не создала филиала, не открыла представительства или не учредила российское юридическое лицо

14.01.22 • Гайнутдинова Лиана, Finam.ru
Фиаско РФ в переговорах по европейской безопасности обрушило рубль и российский рынок
Старый Новый год на отечественной бирже в этом году был омрачен массированным выходом нерезидентов из российских бумаг под давлением усилившихся геополитических рисков

14.01.22 • Finam.ru
Сенатор США подготовил новый проект санкций против России и лично Путина
Предполагается, что в случае принятия законопроекта, США смогут ввести санкции против России и президента в ответ на вторжение на Украину

14.01.22 • РИА Новости
Добыча нефти в России в январе составит 10,1 млн баррелей в сутки - Новак
Штамм коронавируса "омикрон" меньше предыдущих штаммов влияет на спрос на нефть в мире, что обуславливает решения альянса ОПЕК+ по объемам добычи

9

Работа парсера новостей



Котировки Aeroflot (AFLT) за

ru.investing.com/equities/aeroflot-historical-data

Браузером Chrome управляет автоматизированное тестовое ПО.

Investing.com

Открыть приложение

Акции Фильтр акций Россия Премаркет США Мировые АДР Россия - АДР Америка Европа Бл. В

Новинка! Приобретите ProPicks и узнайте стратегию, опередившую S&P 500 более чем на 1,183% Получить СКИДКУ 40%

ОАО Аэрофлот (AFLT)

Москва Цена в RUB Предупреждение

★ Добавить в портфель

49,36 +0,93 (+1,92%) ▲

Закр. 05/04

Обзор График Новости и аналитика Отчеты Теханализ Форум

Обзор Профиль Прошлые данные Компонент индексов

Прошлые данные - AFLT

Временной период

Daily 01.01.2022 - 01.01.2024

Дата	Цена	Откр.	Макс.	Мин.	Объем	Изм. %
29.12.2023	35,05	35,10	35,40	34,70	7,78M	...
28.12.2023	34,87	35,11	35,22	34,71	7,92M	-0.68%

Работа парсера котировок



» 2. Предобработка данных

Алгоритм предобработки:

1. Приведение к нижнему регистру;
2. Очистка текста от пунктуации, цифр и англоязычных слов и букв;
3. Выделение леммы из каждого слова;
4. Удаление стоп-слов;
5. Удаление редко и часто встречающихся слов.

Пример

«Чистая прибыль АФК "Система" по US GAAP в 2013 году выросла на 11,1% - до \$2 млрд».

1. «чистая прибыль афк "система" по us gaap в 2013 году выросла на 11,1% - до \$2 млрд»
2. «чистая прибыль афк система по в году выросла на до млрд»
3. «чистый прибыль афк система по в год вырастать на до млрд»
4. «чистый прибыль афк система вырастать»
5. «чистый прибыль вырастать»



» 3. Анализ тональности новостей

При проведении анализа тональности используется нейросеть **RuBERT-base-cased-sentiment**, основанная на архитектуре трансформеров.

На выходе нейросети формируется вектор тональности:

$$Tonality = [Neutral, Positive, Negative],$$

где *Neutral* – нейтральная составляющая текста;

Positive – позитивная составляющая текста;

Negative – негативная составляющая текста.

Пример

Входные данные: «выручка группа включая прочий деятельность увеличиваться примерно прошлое материал алмазодобыча карат реализация запас нейтральный динамика алмазный квартал придерживаться прогноз число ювелирный качество средний технический».

Выходные данные:

Positive: 0.925;

Neutral: 0.06;

Negative: 0.014.



» 4. Создание нейронных сетей

□ Подготовка данных

Входные данные:

$$\text{Input} = \left[\begin{array}{c|c} a_{1,1} \dots a_{1,k} & b_{1,1}, b_{1,2}, b_{1,3} \\ \dots & \dots \\ a_{m,1} \dots a_{m,k} & b_{m,1}, b_{m,2}, b_{m,3} \end{array} \right],$$

где $a_{i,j} (i = \overline{1, m}, j = \overline{1, k})$ – значения временных рядов показателей акции;

$b_{i,l} (i = \overline{1, m}, l = \overline{1, 3})$ – значения координат векторов тональности;


m – шаг обратного просмотра;

k – количество параметров обучающего набора.

Выходные данные:

$$\text{Output} = \hat{y},$$

где $\hat{y}$ – прогнозное значение цены акции.



В модели присутствуют
слои:

- **LSTM** – основной слой обработки данных
- **Dropout** – слой для предотвращения переобучения
- **Dense** – слой для задания параметров регуляризации
- **Activation** – слой для вычисления функции активации в интервале от 0 до 1


» 4. Создание нейронных сетей

□ Обучение нейросетей

По результатам обучения моделей строится график метрик **MSE** и **MAE** в зависимости от эпох обучения.

В качестве примера рассмотрим компанию Алроса, для которой были получены следующие метрики:


	MSE	RMSE	MAE	MAPE
Тренировочное значение	12,549	3,542	2,722	3,535 %
Тестовое значение	47,141	6,866	4,891	5,062 %



Изменение метрик модели для компании Алроса

»» 4. Создание нейронных сетей

□ Анализ работы нейросетей





»» 4. Создание нейронных сетей

□ Анализ работы нейросетей



График фактических и предсказанных цен для компании Алроса на тестовых значениях



»» 4. Создание нейронных сетей

□ Анализ работы нейросетей



Матрица корреляции параметров



» 4. Создание нейронных сетей

□ Анализ работы нейросетей

	MSE	RMSE	MAE	MAPE
Тренировочное значение	12,549	3,542	2,722	3,535 %
Тренировочное значение без тональности	26,222	5,120	4,253	5,426 %
Отклонение	108,95 %	44,55%	56,24%	53,49 %
Тестовое значение	47,141	6,866	4,891	5,062 %
Тестовое значение без тональности	93,584	9,674	7,227	7,219 %
Отклонение	98,52 %	40,90 %	47,76 %	42,61 %


Таким образом, использование тональной составляющей при создании и обучении нейросети положительно сказывается на выдаваемом прогнозном значении.



»» 5. Прогнозирование цен акций

❑ Разработка процесса ETL

Для автоматического ежедневного прогнозирования цен акций был создан ETL-процесс для сбора и обработки данных. Внутри ОС Ubuntu с Apache Airflow данный процесс представлен в виде ориентированного ациклического графа (DAG).



Представление DAG внутри Apache Airflow



»» 5. Прогнозирование цен акций


❑ Разработка Телеграм-бота

После настройки процесса ETL необходимо оповещать пользователей о полученной информации.

Для этих целей используется Telegram бот, выполняющий ежедневные запросы к сформированной базе данных, и отправляющий полученные данные в чат.

```
По итогам сегодняшнего дня (2024-06-05) был составлен
следующий прогноз:
afks : 12.3 ₺
aflt : 27.34 ₺
agrodr : 664.8 ₺
alrs : 60.7 ₺
cbom : 7.33 ₺
chmf : 875.2 ₺
enpg : 416.5 ₺
fees : 0.09 ₺
fivedr : 1513.0 ₺
flot : 42.45 ₺
gazp : 157.88 ₺
```

Пример сообщения от бота



QR-код для подключения бота







»» Выводы

1. На основе анализа предметной области был сделан вывод, что выбранная тема ВКР актуальна и требует дальнейшего развития.
2. Разработан алгоритм работы системы прогнозирования курсов акций.
3. Собраны исходные данные: новости по 49 компаниям (97 572 записи), а также показатели акций этих компаний за 2014 – 2024 года.
4. С помощью алгоритма лемматизации, а также встроенных Python функций весь объем текстовых данных предобработан.
5. На основе значений тональной составляющей новостей, а также значений показателей акций компаний-эмитентов построены и обучены 49 моделей нейросетей.
6. В ходе вычислительного эксперимента выявлено влияние и целесообразность учёта тональной составляющей при нахождении прогнозных цен акций.
7. Разработано программное обеспечение, способное ежедневно прогнозировать цены акций.



УФИМСКИЙ
УНИВЕРСИТЕТ
НАУКИ И ТЕХНОЛОГИЙ

**Спасибо за
внимание!**

